

Università di Trento

Dipartimento di Ingegneria dell'informazione

Laurea Triennale in Ingegneria Informatica

~ · ~

Anno Accademico 2025-2026

Rilevamento di Cambiamenti Multitemporali nei Dati Radar Sounder per il Monitoraggio della Criosfera

Supervisori
Prof. Lorenzo Bruzzone,
Dott.ssa Elena Donini,
Dott.ssa Francesca Bovolo

Studente
Alessandro Weber
244841

Ringraziamenti

Durante questi tre anni universitari oltre alla formazione ricevuta ed ai bei momenti passati credo di essere cresciuto e so che questo traguardo è solo un punto di partenza. Ci tengo a dedicare questi ringraziamenti a chi c'è sempre stato e mi ha cresciuto e appoggiato.

Un grazie ai miei genitori e al Max che mi hanno aiutato, supportato e sopportato durante questo percorso.

Un ringraziamento anche alla vicinanza di tutti i nonni, zii e famigliari per il supporto e l'aiuto durante il tragitto.

Un grazie di cuore a tutti gli amici che mi hanno accompagnato e fatto passare degli anni memorabili e spensierati.

Un sincero grazie ai compagni di università per il supporto e per esserci stati tra tutti questi corsi, esami, studiate e festicciole.

Un grazie ad Elena ed a FBK per l'immenso aiuto nel tirocinio e nella stesura della Tesi.

L'autore ha usufruito del supporto dell'intelligenza artificiale limitatamente alle fasi di correzione bozze e di miglioramento della fluidità espositiva. L'autore si assume la piena responsabilità scientifica e redazionale dei contenuti, garantendo l'originalità e la verifica autonoma delle fonti citate.

Sommario

La tesi tratta il rilevamento di cambiamenti multitemporali nei dati radar sounder per il monitoraggio della criosfera. Questo percorso è stato svolto nella Fondazione Bruno Kessler (FBK) e si è basato sullo studio di metodi di analisi e utilizzo di reti neurali. Viene trattata la manipolazione dei rilevamenti radar sounder sull'Antartide e spiegato il funzionamento di tale strumento. Sul lavoro svolto vengono poi presentate le tecniche utilizzate e il metodo proposto per trovare cambiamenti nelle stratigrafie glaciali. Tale metodo si basa sull'utilizzo delle feature di una rete neurale e la loro manipolazione per evidenziare sui radargrammi i cambiamenti rilevati.

Indice

Introduzione **2**

1 Radar Sounder **6**
1.1 Definizioni e caratteristiche generali 6
1.2 Funzionamento e Principi 6
1.3 Strumenti e missioni 9

2 Metodologia **10**
2.1 Allenamento reti neurali 10
2.2 Estrazione e selezione delle feature 12
2.3 Change Vector Analysis (CVA) sulle feature 13
2.4 Clustering e visualizzazione spaziale dei cambiamenti 15
2.5 Architettura Shallow-net 16

3 Descrizione del dataset **20**
3.1 Preprocessing, allineamento e pipeline di co-registrazione 21
3.2 Divisione in patch 23

4 Risultati **24**
4.1 Modifiche sulla rete 25
4.2 Modifiche nella CVA 31

Conclusioni **36**

Riferimenti bibliografici **38**

Introduzione

La criosfera nel tempo ha dimostrato essere sensibile ai cambiamenti climatici e quindi studiandola si possono dedurre i suoi cambiamenti intrinseci ma anche capire cosa avviene su un piano più globale. Andando a studiare in particolare le grandi masse glaciali come Groenlandia o Antartide si possono quantificare questi cambiamenti ed evidenziare il problema dell'innalzamento del mare in quanto tutta la massa sciolta va ad alimentare lo scioglimento. Il ritiro di ghiacciai e lo scioglimento dei poli è un fenomeno che porta a un riscaldamento globale in quanto le superfici glaciali riflettono i raggi solari, al contrario della superficie acquatica che li assorbe. I ghiacciai terrestri inoltre forniscono per intero l'agricoltura di acqua dolce e il fabbisogno di ogni popolazione, essendo la più grande riserva di acqua dolce (70 % dell'acqua dolce sul pianeta) [6].

Nel nostro caso per studiare i cambiamenti della criosfera si utilizzano dei radar sounder [5] ovvero degli strumenti radar che riescono a raccogliere informazioni sotto le superfici glaciali e a generare così delle immagini verticali rappresentanti gli strati sottostanti al ghiaccio fino alla bedrock (Figura 1), riuscendo a evidenziarne la struttura stratificata. Possiamo definire questi radargrammi come delle immagini 2D che contengono informazioni su ciò che il radar ha ricostruito nel sottosuolo rispettivamente in orizzontale e verticale.

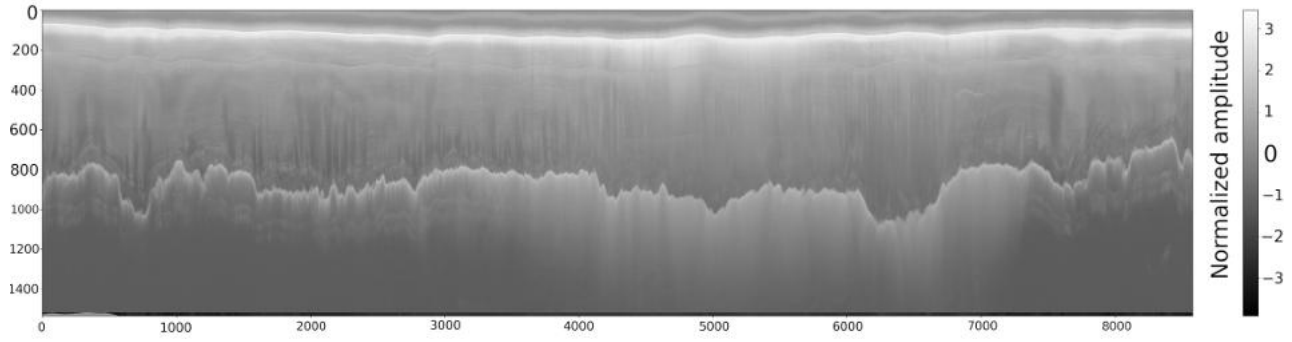


Figura 1: Esempio di un'immagine radar sounder.

Questo metodo si affianca ai più vecchi metodi di carotaggio e immagini satellitari, rendendo lo studio degli strati inferiori del ghiacciaio più rapido e disponibile su zone più ampie. Inoltre grazie ai radar sounder possiamo proprio vedere le strutture e la stratificazione nei ghiacci, cosa assente in altri metodi. Il ruolo dei radar sounder è rilevante anche nelle missioni spaziali perchè sono in grado di fornirci informazioni chiare sul sottosuolo geologico e la composizione dei pianeti come: Marte, Luna, Venere e delle lune gioviane. Ad esempio su Marte hanno catturato in maniera completa la situazione sui poli con presenza di ghiaccio [5].
Le acquisizioni di tipo singolo (single-pass) non evidenziano cambiamenti rilevanti ma possono essere di aiuto per lo studio di strutture e caratteristiche delle superfici glaciali.
Le campagne radar sounder di tipo multi-temporale [6] (ovvero un rilevamento sulla stessa zona in tempi diversi) hanno permesso le prime analisi dei cambiamenti in quanto ci permettono di distinguere le differenze tra i radargrammi di due periodi, evidenziando cambiamenti che una singola aquisizione non riuscirebbe, come: cambiamenti nella stratigrafia, spostamenti degli strati glaciali (sliding), ablazioni, spostamenti di ghiaccio/neve o fusione in corso. Seppur disponiamo di poche campagne bi-temporali riusciamo comunque a dimostrare la loro rilevanza scientifica, in quanto permettono di monitorare delle zone di cambiamento e instabilità, ad esempio sul firn, dove avviene la percolazione (dove l'acqua di fusione degli strati superiori penetra nei substrati inferiori).
Lo studio della criosfera può essere diviso in: cambiamenti attesi e cambiamenti inattesi [6]. I primi (expected changes [7]) possono essere identificati da movimenti naturali delle calotte, come gli eventi di slittamento orizzontale che portano il ghiaccio verso la costa e hanno maggiore velocità di avanzamento negli strati superiori. Questi sono attenuati e mitigati dalla co-registrazione [7].
I secondi invece sono tutti i cambiamenti morfologici e sono spiegabili dai glaciologi, in quanto rappresentano il reale cambiamento climatico essendo un alterazione della stratigrafia o anomalia sulla zona basale [6].

Sviluppare un metodo automatico per osservare i cambiamenti sulle immagini bitemporali è molto importante e non può essere svolto in maniera manuale: in primis la mole dei dati è abbastanza importante e ciò porta a molto tempo impiegato per questa operazione di rilevamento dei cambiamenti e anche la soggettività incide

sull'analisi [5]. Inizialmente le feature per analizzare i radargrammi erano definite manualmente, tenendo in considerazione la tipologia di problema da evidenziare e di conseguenza molto specifiche e poco generalizzabili [8]. Se vogliamo però trattare dei radargrammi con metodi automatici la situazione cambia poichè essi sono dei dati più complessi da elaborare e analizzare, in quanto possiedono parte reale e immaginaria, rumore ed inoltre presi singolarmente non contengono informazioni definite e estese come un'immagine multispettrale che dispone di decine di bande. I radargrammi sono anche poco reperibili etichettati, perchè non disponiamo di dati etichettati su larga scala ma abbiamo verità a terra limitate che rendono difficili training supervisionati senza overfittare il modello [8]. Ciò significa che un modello riesce a distinguere bene tra rumore e segnale utile ma non riesce a distinguere facilmente le classi, ad esempio differenza tra roccia basale e ghiaccio. Le mappe di verità sono fondamentali anche per la validazione dei modelli non supervisionati, sui quali si sta spostando i nuovi metodi di analisi in quanto più efficaci. Un esempio di validazione è la composizione false color: si basa su diversi colori in base al periodo di acquisizione (2014 verde e 2016 magenta), in modo da colorare le zone in cui l'intensità riflessa era maggiore in un anno, risultando in zone grigie o bianche dove abbiamo un'immagine corrispondente, magenta dove il 2016 domina e verde dove il 2014 aveva maggiore intensità retroriflessa (Figura 2). Questo consente di definire i cambiamenti nel radargramma [7].

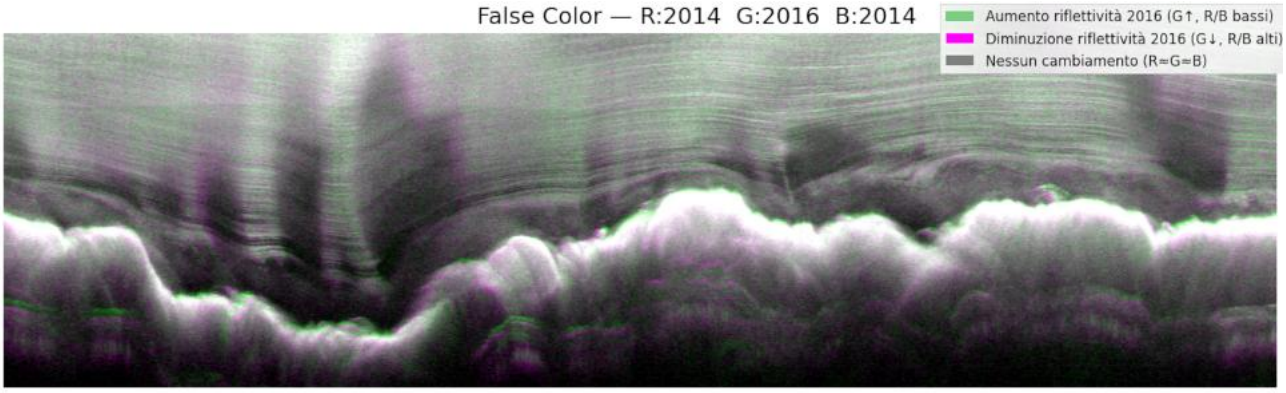


Figura 2: Esempio di un'immagine false color su un radargramma (tra il 2014 e il 2016) dove definiamo come colore prevalente 2014 in verde e 2016 magenta.

I diversi momenti di acquisizione nei radargrammi bitemporali hanno ovviamente portato a dei disallineamenti nelle acquisizioni dovuti al diverso percorso o altezza dell'aereo con a bordo il sensore MCoRDS-3 (in quanto è difficile mantenere una traiettoria precisa) [6], errori di propagazione, scattering del radar e movimento naturale delle calotte stesse. E' perciò importante la correzione di tali errori e co-registrare entrambi i dati per renderli la cattura in due momenti della stessa porzione di ghiaccio. Una volta allineati entrambi vengono eseguite varie tecniche di analisi e manipolazione delle immagini per riuscire a trovare dei cambiamenti temporali significativi nei substrati delle calotte polari:

- **Sogliatura automatica**: si occupa di evidenziare i cambiamenti tra le due immagini e nello specifico fa l'operatore log-ratio (il logaritmo del rapporto tra le due intensità di retrodiffusione) e poi va a applicare la sogliatura di Otsu, in modo da ottenere una mappa dei cambiamenti binaria che indica i pixel cambiati [6];
- **Interferometria differenziale (DInSAR)**: consiste nel rilevare spostamenti verticali negli strati glaciali, distinguendo movimenti naturali da variazioni dello spessore dello strato [7];
- **Deep change vector analysis (DCVA)**: invece di utilizzare i singoli pixel vengono passate le feature di una CNN così da avere dei vettori di feature (Figura 15) [1];

Per rilevare i cambiamenti, procediamo con una divisione in patch di dimensioni minori. Questa operazione è importante perchè porzioni di radargramma diverse hanno diversi tipi di cambiamento rilevabili in base alla loro localizzazione, soprattutto se osserviamo diversi tipi cambiamento sulla superficie o nella zona basale. Inoltre, i cambiamenti sul radargramma intero sono poco definiti perchè, tutto sommato, non abbastanza impattanti e quindi risulta un'analisi migliore su piccola scala e concentrata.
Nel nostro caso sono state utilizzate le analisi della CVA (Change Vector Analysis) con le feature di una Shallow-net (Figura 8). Queste analisi trasformano un dato grezzo e ne definiscono la forma. Le analisi delle CVA, portate sull'immagine, possono rappresentare dei precisi cambiamenti interpretabili come: compattazione

del firn e deformazione degli strati di ghiaccio [6].
Grazie agli strumenti di analisi dei cambiamenti bitemporali e alla possibilità di eseguire queste campagne di telerilevamento, possiamo monitorare la parte invisibile della criosfera, permettendoci di comprendere come le calotte si stanno mutando e di capire la stabilità dei ghiacciai contro il riscaldamento climatico.

Radar Sounder

1.1 Definizioni e caratteristiche generali

I radar sounder sono dei sensori attivi progettati per l'indagine del sottosuolo terrestre e dei corpi celesti. A differenza dei tradizionali radar, che rilevano la superficie, i radar sounder trasmettono onde elettromagnetiche a basse frequenze che consentono di ricostruire il sottosuolo tramite gli echi: tutto ciò avviene in modo non intrusivo. Questa operazione avviene sulla Terra portando il sensore tramite aereomibili e nello spazio sui satelliti [5].

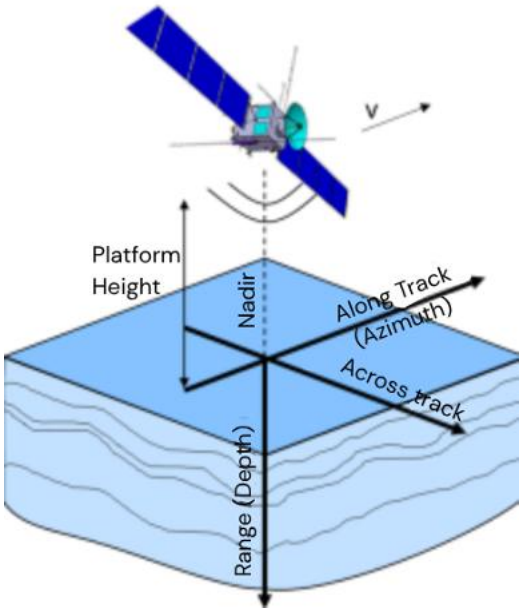


Figura 3: Direzioni e definizioni degli orientamenti [5].

Tecnicamente i radar sounder si occupano di trasmettere verso il nadir (perpendicolarmente al terreno, Figura 3) una specifica onda elettromagnetica: HF (High frequency) tra 3 e 30 MHz e VHF (Very High Frequency) tra 30 e 300 MHz con solitamente bande larghe fino a 100 MHz. Queste basse frequenze permettono la penetrazione ricercata dai radar sounder, a discapito della risoluzione spaziale preferita dai radar tradizionali per l'imaging (onde HF sono preferite per la penetrazione, a bassa frequenza, mentre le VHF consentono una risoluzione verticale maggiore). Possiamo anche osservare dalle missioni che le HF sono preferite nello spazio, dove i target sono più distanti, mentre le VHF sono preferite sulla Terra (mediante aerei) per una maggiore definizione.
Il segnale, penetrando nel sottosuolo, viene propagato e, a causa delle diverse proprietà dielettriche dei materiali che lo compongono, subisce riflessioni in corrispondenza delle discontinuità. Gli echi riflessi vengono sommati coerentemente andando a comporre un radargramma.

1.2 Funzionamento e Principi

Il radar sounder ha un'antenna dipolo che trasmette e riceve. L'onda trasmessa al suolo viene riflessa in base alla zona illuminata e a vari fattori definiti nella formula del radar (Formula 1) [5]:

$$P_r = \frac{P_t\, G^2\, \lambda\, \sigma_0\, A_{\text{ill}}}{(4\pi)^3\, d^4} \tag{1}$$

- P_r: Potenza ricevuta (W) – potenza del segnale radar riflesso e catturato dall'antenna
- P_t: Potenza trasmessa (W) – potenza dell'impulso radar emesso dall'antenna
- G: Guadagno dell'antenna (adimensionale) – fattore che descrive l'efficienza direzionale dell'antenna
- λ: Lunghezza d'onda (m) – lunghezza d'onda del segnale radar, legata alla frequenza f da $\lambda = c\,f$

- σ_0: Coefficiente di retrodiffusione (adimensionale) – parametro che descrive la riflettività della superficie (radar cross-section per unità di area)
- A_{ill}: Area illuminata (m^2) – area della superficie illuminata dal fascio radar
- 4π: Fattore geometrico – deriva dalla propagazione sferica del segnale in spazio libero
- d: Altitudine (m) – altezza del sensore radar rispetto alla superficie (illuminata)

Possiamo determinare che potenza trasmessa, guadagno dell'antenna e distanza sono costanti nel caso le misurazioni avvengano sul suolo terrestre: l'antenna è sempre la stessa e la distanza dal suolo è pressoché costante perchè monitorata nelle campagne che vengono effettuate. Ciò che determina maggiormente i cambiamenti della potenza di ritorno sono direttamente le proprietà dielettriche del materiale rappresentate dal coefficiente di retrodiffusione.
Molto importante è anche la frequenza centrale (λ) in quanto, più la frequenza è bassa, maggiore è la penetrazione e quindi ha un'attenuazione inferiore. Inoltre le onde elettromagnetiche subiscono attenuazioni e assorbimenti che dipendono dal mezzo di propagazione. Questo fenomeno è influenzato dalle proprietà dispersive e dissipative del reticolo a seconda del materiale di propagazione e ne determinano la profondità massima investigabile, ad esempio, nel ghiaccio il segnale penetra chilometri mentre in terreni aridi e basaltici è più attenuato.
La propagazione dell'onda è descritta dalle equazioni di Maxwell mentre la legge di Snell ne descrive l'incidenza e rifrazione quando passa tra due mezzi differenti [5]. L'onda elettromagnetica quando colpisce una nuova superficie o un nuovo materiale viene riflessa, assorbita e propagata, di conseguenza, ciò che ritorna al radar è un'onda che ne indica anche le caratteristiche.
Per descrivere i cambiamenti di velocità che avvengono sull'onda nel passaggio in un nuovo mezzo possiamo utilizzare la seguente legge (Formula 2) [5]:

$$c = \frac{1}{\sqrt{\epsilon_0\,\mu_0}} \qquad v_{\text{medium}} = \frac{c}{\sqrt{\epsilon_r\,\mu_r}} \tag{2}$$

- c Velocità della luce nel vuoto ($\approx 3 \times 10^8$ m/s)
- v_{medium} Velocità di propagazione dell'onda nel mezzo
- ε_0 Permittività elettrica del vuoto (8.854×10^{-12} F/m)
- μ_0 Permeabilità magnetica del vuoto ($4\pi \times 10^{-7}$ H/m)
- ε_r Permittività dielettrica relativa (costante dielettrica relativa) del mezzo
- μ_r Permeabilità magnetica relativa del mezzo

Si può notare che nel vuoto l'onda ha una certa velocità mentre in un mezzo cambia la sua velocità secondo le variabili di permettività e permeabilità ($\epsilon_\mathbf{r}, \mu_\mathbf{r}$). Per di più le velocità raggiunte nel mezzo non possono essere maggiori di c, perciò i coefficienti sopra indicati (permettività e permeabilità) devono essere maggiori di 1 [5].
Le riflessioni avvengono nel passaggio da un mezzo di trasmissione all'altro dell'onda, quindi dai materiali con diverse costanti dielettriche: ad esempio roccia-ghiaccio e ghiaccio-acqua (Figura 1). L'intensità della riflessione dipende da cosa l'onda colpisce e va a formare diverse retrodiffusioni ad esempio un netto cambiamento del mezzo, come con l'interfaccia basale, determina dei picchi di potenza nel ritorno dell'onda. I cambiamenti delle proprietà dei cristalli del ghiaccio sono determinati da una variazione del mezzo e, di conseguenza, della potenza dell'eco. Sono presenti anche picchi del segnale in caso di acqua e un'attenuazione/assorbimento evidente da parte di essa (Figura 4).
La profondità dell'oggetto che forma l'eco (z) è determinata dalla velocità media del mezzo nel quale è trasmessa (v_{medium}) e inoltre sapendo il Return Trip Time (RTT) della precisa onda (quanto tempo passa tra la trasmissione e la ricezione) possiamo ricavare (Formula 3) [5]:

$$z = \frac{v_{\text{medium}} \cdot \text{RTT}}{2} \tag{3}$$

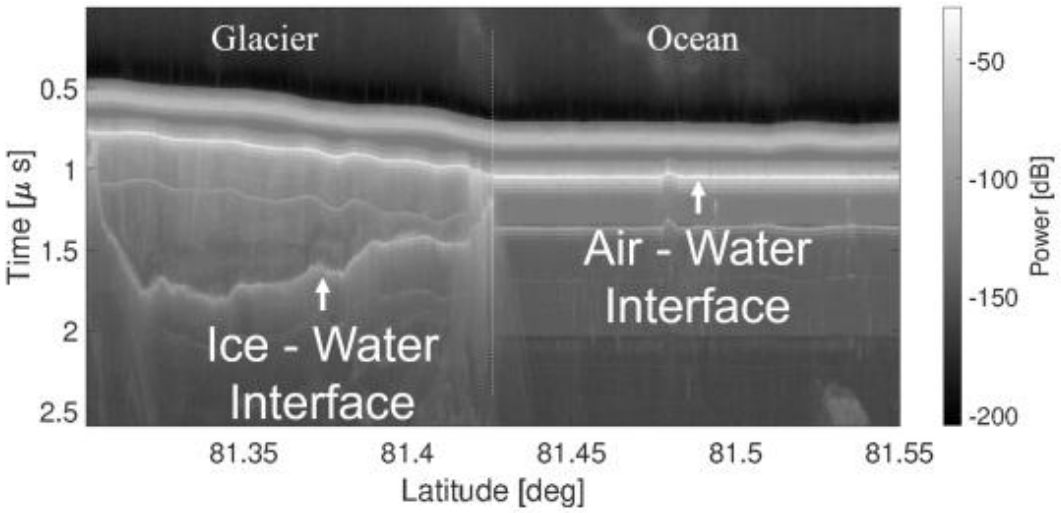


Figura 4: Esempio di un'immagine radar sounder che dimostra l'eco dell'onda sull'acqua e sulle interfacce glaciali [5].

Per determinare la velocità media è necessaria un'analisi preliminare per calcolare le proprietà del materiale che si andrà ad analizzare con il radar sounder.
I movimenti della piattaforma sono lungo l'azimuth (direzione di volo), nadir (range, che indica la direzione verticale, cioè della profondità) e across-track (che rappresenta la direzione ortogonale rispetto alle altre due) (Figura 3).

La risoluzione in profondità (range) è inversamente proporzionale alla larghezza di banda (BW): banda più larga consente di avere più dettagli, ma frequenze più elevate penetrano meno in profondità [2]. Tale fenomeno è descritto dalla formula di risoluzione di range:

$$r_{GR} = \frac{c}{2BW \sin \theta_i} \tag{4}$$

dove:

- r_{GR}: ground range resolution
- c: velocità della luce
- BW: banda trasmessa dal radar sounder
- θ_i: angolo di incidenza

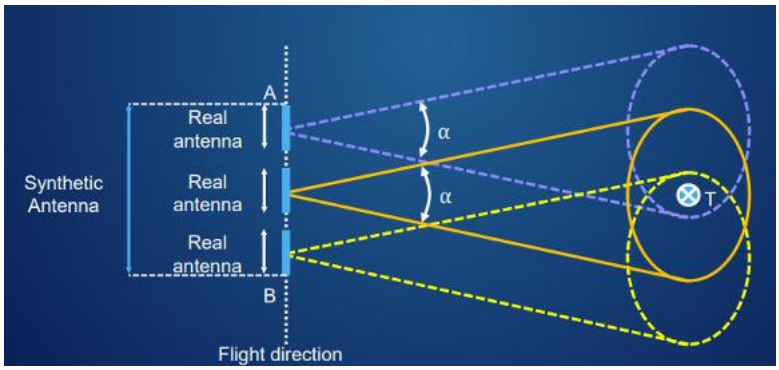


Figura 5: Funzionamento del SAR (Synthetic Aperture Radar): Il velivolo prosegue lungo la sua direzione di volo e cattura più volte la stessa porzione di ghiaccio e ne ricostruisce un'immagine più definita [2].

La risoluzione along-track rappresenta la risoluzione della zona illuminata lungo l'azimuth e viene migliorata

con tecniche di filtraggio Doppler (come il SAR processing Figura 5) simulando e ricostruendo come se si utilizzasse un'antenna più grande. Ciò significa che come mostrato nella Figura 5 il radar illumina più volte l'area interessata e di conseguenza ha più riflessi di quell'oggetto e raccoglie più informazioni su di esso. Il SAR è una tecnica che avviene nel post-processing che ricostruisce il radargramma utilizzando più riflessioni, aumentando così la risoluzione del target. Questo è possibile con l'introduzione della fase nell'elaborazione delle onde che altrimenti utilizzerebbe solo l'ampiezza, che non renderebbe possibile questa particolare tecnica [2].

1.3 Strumenti e missioni

Questi radar, che riescono a penetrare superfici, possono essere usati, oltre a scopi di ricerca in Antartide o nello spazio, anche in contesti molto diversi. Questa capacità di riconoscere la presenza di altri materiali o oggetti nel sottosuolo li rende validi nel contesto del monitoraggio del sottosuolo urbano, analisi su siti archeologici, per la ricerca di sacche di gas o giacimenti di petrolio e per il rilevamento delle mine anti uomo.
Possiamo suddividere i tipi di radar sounder usati nel remote sensing in vari ruoli e missioni [5]:

- Marte: MARSIS (2005) che ha rilevato ghiaccio sui depositi polari e un lago subglaciale al polo sud. Seguita poi da SHARAD, che ha contribuito con un sensore a frequenza maggiore per catturare in maniera migliore le stratigrafie dei ghiacciai polari;
- Luna: LRS (2007) che ha rilevato stratificazioni e resti vulcanici;
- lune di Giove: RIME (sensore montato su JUICE, sonda dell'ESA) analizzerà le strutture delle croste ghiacciate e ricercherà depositi di acqua liquida. REASON che studierà l'abitabilità di Europa e la sua geodinamica;
- SRS sarà inviato verso Venere per definirne l'attività geologica e rilevare crateri e attività lavica;
- Sulla Terra possiamo definirli in base ai differenti ambienti di studio: criosfera e aree aride;

Le campagne effettuate sulla criosfera sono costose e ripetitive, quindi si stanno sviluppando progetti in grado di rendere un sistema orbitante con la qualità delle scansioni alla pari degli aerei (che operano più vicino alla superficie). Queste campagne sono STRATUS e OASIS, che mirano ad una copertura globale e costante.

Metodologia

L'interpretazione di radargrammi e la capacità di identificarne le differenze sono fondamentali per comprendere i cambiamenti della criosfera, rendendo importante lo sviluppo di metodi automatici per la mappatura dei cambiamenti fisici tra radargrammi multitemporali.
Per evitare di evidenziare zone che non rappresentano cambiamento (come piccoli pixel differenti) e garantire un'analisi più completa del ghiacciaio si opera a livelli più astratti e non pixel-wise, utilizzando rappresentazioni semantiche da reti neurali più precisamente, CNN con aggiunte di moduli per modificarne il comportamento.
Il metodo utilizzato nel nostro caso si basa sull'utilizzo di una shallow-net poi modificata, per adattarla all'analisi dei radargrammi, e prevede l'estrazione delle feature interne. Successivamente c'è una selezione delle feature per varianza e SSIM. Per concludere le feature selezionate vengono rappresentate da una CVA o una S2CVA, per poi essere suddivise mediante un clustering kmeans basato sul silhouette score che crea degli overlay da applicare all'immagine.

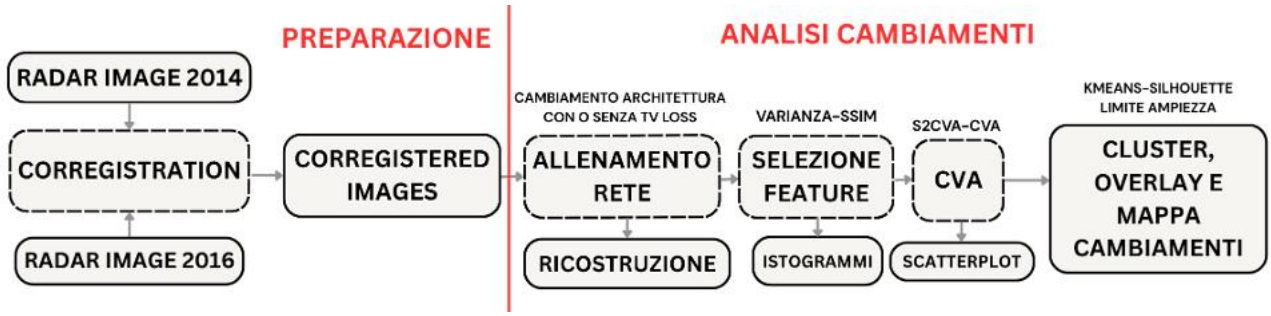


Figura 6: Catena dei processi effettuati per l'analisi, tratteggiati i procedimenti e linee continue i dati e risultati.

2.1 Allenamento reti neurali

L'allenamento avviene su una rete leggera (nel nostro caso una Shallow CNN con ASPP, Atrous Spatial Pyramid Pooling, e BiConvLSTM, Bi-Convolutional Long Short-Term Memory, Figura 8) che viene addestrata come autoencoder sulle patch del 2014, ovvero il modello utilizza canali di input duplicati sulla stessa immagine e cerca di ricostruire l'immagine in output (utilizzando tv loss per l'apprendimento). L'assenza di layer di pooling/upsampling preserva la risoluzione, rendendo le feature interne adatte al confronto diretto tra le immagini e alla ricerca di differenze precise ed anche per la ricostruzione. Questo perchè gli strati di pooling/upsampling riducono risoluzione e snaturano l'immagine, perchè cambiano la risoluzione e alterano i valori dei pixel e dell'immagine. Alla fine del processo di training si procede alla ricostruzione dell'immagine sulle immagini del 2014 e del 2016, e si calcolano le differenze con l'immagine originale per verificare che la rete sappia rappresentare a pieno l'immagine (Figura 7).
Il processo di ottimizzazione dei pesi non si basa solo sulla classica MSE, errore quadratico medio, ma anche su un vincolo di regolarizzazione spaziale, tv loss (Formula 5) [10].

$$L_{\text{total}} = L_{\text{MSE}}(x, \hat{x}) + \lambda_{\text{TV}}\, L_{\text{TV}}(F) \tag{5}$$

dove

- $L_{\text{MSE}}(x, \hat{x})$ è la perdita di ricostruzione (MSE), che assicura che l'output $\hat{x}$ sia il più fedele possibile all'input x.
- $L_{\text{TV}}(F)$ è la perdita di Variazione Totale applicata al tensore delle feature interne $F \in \mathbb{R}^{C\times H\times W}$ all'uscita dello strato Bi-ConvLSTM.
- λ_{TV} è il peso parametrico (configurato tra 10^{-3} e 10^{-2}) che regola l'intensità della regolarizzazione.

Il tensore F è definito come:

$$F = [F_{ch,h,w}]_{ch=1..C,\, h=1..H,\, w=1..W} \in \mathbb{R}^{C\times H\times W} \tag{6}$$

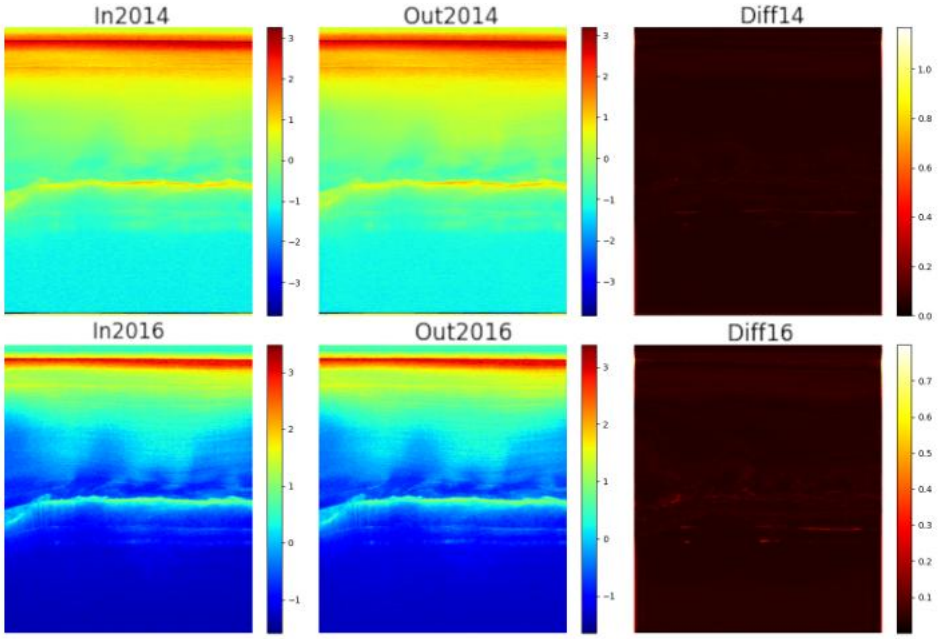


Figura 7: Operazione post train che permette di verificare che la rete sappia ricostruire le immagini e quindi vedere l'output della rete e paragonarlo all'immagine originale: $in - out$ (per trovare le differenze). Sulla riga superiore abbiamo le immagini del 2014 mentre in quella inferiore 2016. Determiniamo che con le immagini del 2016 dove non avviene il train la differenza ha maggiore intensità (marcato in rosso).

con:

- C: numero di canali (feature channels),
- H: altezza del tensore (dimensione spaziale verticale),
- W: larghezza del tensore (dimensione spaziale orizzontale).

La tv loss si occupa di penalizzare variazioni brusche tra pixel vicini nei valori delle feature in modo da ottenere mappe delle caratteristiche planari per attenuare rumore e rendere omogenee le regioni con caratteristiche simili. Questa tecnica si presta per questo utilizzo in quanto i cambiamenti essendo spesso lineari orizzontalmente sugli strati glaciali vengono uniformizzate le zone di cambiamento. A livello matematico si calcola la norma del gradiente della mappa di feature (Formula 7) [10].

$$\mathrm{L_{TV}(F)} = \mathrm{mean}\big(|\Delta \mathrm{h}|\big) + \mathrm{mean}\big(|\Delta \mathrm{w}|\big) \tag{7}$$

dove Δh e Δw rappresentano i gradienti parziali discreti in verticale e orizzontale, e si occupano di trovare discontinuità nei pixel (su Pytorch avviene con la Formula 8):

$$\begin{aligned} \Delta h &= F[:,:,1:,:] - F[:,:,:-1,:], \\ \Delta w &= F[:,:,:,1:] - F[:,:,:,:-1]. \end{aligned} \tag{8}$$

Ciò significa che l'algoritmo scorre l'intera immagine prima per altezza e poi orizzontalmente e si calcola le differenze di valore tra pixel adiacenti, in modo da penalizzare i salti di valore e mantenere regioni omogenee. L'utilizzo della tv loss è sostenuto anche dalla letteratura, per la preservazione dei bordi e riesce a mantenere forme e strutture più continue rispetto alla MSE senza tv loss, concedendo bordi più nitidi alle figure [16]. Invece per la soppressione del rumore e pixel non coerenti rende le variazioni ad alto valore del pixel poco significative e valorizza strutture spaziali [16]. Questa operazione è effettuata all'uscita della Bi-ConvLSTM (Figura 8), poichè essa modella la correlazione orizzontale (lungo la traccia di volo), la tv loss consente che la coerenza non sia solo spazio-temporale ma anche spaziale [4].
La shallow net modificata è finalmente pronta ad estrarre le feature del 2014 e del 2016, in maniera continua e senza rumore.

2.2 Estrazione e selezione delle feature

La selezione delle feature è un passaggio fondamentale in quanto rende più pulito e meno dispendioso il lavoro che spetterà alla CVA. Possiamo dire che le feature sono spesso ridondanti o rumorose e quindi si cerca di utilizzare le feature più caratterizzanti e informative.
Per selezionare in tutto il radargramma un gruppo di feature coerente ed esteso, andiamo a utilizzare immagini intere oppure ad assemblare le patch. Le feature provengono dall'architettura definita dalla Figura 8 nella sezione 2.5 – $Architettura\ Shallow - net$.
Dopo l'estrazione delle feature dai radargrammi dei due anni differenti, si calcola la differenza tra di essi: $X_D = featuremap16 - featuremap14$ (anche detto SCV: Spectral change vector). Successivamente si selezionano dei canali ad alta varianza e vengono mantenuti i canali con maggiore varianza spaziale (calcolata in sotto-regioni), così da concentrarsi sulle dimensioni con cambiamenti [14]. La varianza viene utilizzata per selezionare le feature che effettivamente mostrano cambiamenti in quanto presentano maggiore differenza e variabilità tra valori interni sulla feature map. Inoltre viene effettuata una divisione in quadranti che consente di mantenere anche le sotto-zone dove il cambiamento è significativo ma in una zona specifica. Anche se andiamo a ridurre il numero di features possiamo definire la varianza una misurazione resistente che garantisce la conservazione dei cambiamenti, anche con meno feature, togliendo le feature più rumorose e mantenendo quelle che rappresentano un cambiamento.
La selezione dei canali per varianza opera con questa operazione (Formula 9):

$$Var_{ch} = \frac{1}{N}\sum_{i=1}^{N}(x_{ch,i} - \bar{x}_{ch})^2 \tag{9}$$

dove:

- ch = indice del canale (da 0 a 63)
- $x_{ch,i}$ = valore del pixel i nel canale ch della differenza
- $\bar{x}_{ch}$ = media di tutti i pixel del canale ch
- $N = H \times W$ = numero totale di pixel

Dopo aver selezionato queste feature, vogliamo però utilizzare le più caratterizzanti e uniche senza ridondanza e allora viene effettuata una SSIM (Structure similarity Index Measure) [12] tra le feature map già filtrate dalla selezione per varianza. Per ogni feature viene calcolato quanto risulta simile rispetto alle altre e scelte quelle con SSIM minore in modo che siano meno ridondanti.
La SSIM (Formula 13), tra due immagini A e B, può essere divisa in tre componenti [12]:

- Luminanza (l, Formula 10): che confronta le medie locali (m_A, m_B);

$$l = \frac{m_A m_B + C_1}{m_A^2 + m_B^2 + C_1} \tag{10}$$

- Contrasto (c, Formula 11): Confronta le deviazioni standard locali (s_A, s_B);

$$c = \frac{s_A s_B + C_2}{s_A^2 + s_B^2 + C_2} \tag{11}$$

- Struttura (str, Formula 12): Confronta la correlazione tra le strutture spaziali (s_{AB}).

$$str = \frac{s_{AB} + C_3}{s_A s_B + C_3} \tag{12}$$

$$SSIM = C1[l(Imm_1, Imm_2)] \cdot C2[c(Imm_1, Imm_2)] \cdot C3[str(Imm_1, Imm_2)] \tag{13}$$

Dove $C1$, $C2$ e $C3$ sono delle costanti che servono quando il valore si avvicina molto allo 0 in modo da non azzerare la SSIM e Imm_1 e Imm_2 rappresentano le feature map paragonate. Con l'array di valori di SSIM (lungo 16 valori) si calcola la media e si selezionano i valori più bassi.
Per riuscire a comprendere come le feature vengono selezionate da questi metodi, si creano degli istogrammi illustrativi (Figura 15).

2.3 Change Vector Analysis (CVA) sulle feature

Queste feature map vanno poi analizzate con degli strumenti di CVA (Change vector analysis), che cercano coerenza spaziale nei cambiamenti meglio rappresentati dalle feature e li trasferisce come punti su uno scatterplot secondo i pixel che hanno subito cambiamento (Figura 15). Quindi possiamo determinare delle caratteristiche simili tra questi strumenti:

- Riduzione dimensionale: proietta i vettori differenza selezionati in uno spazio bidimensionale;
- Rappresentazione polare: il cambiamento di ogni pixel viene rappresentato tramite magnitudine e angolo in coordinate polari;
- Filtraggio: vengono mantenuti per l'analisi solo i cambiamenti significativi tramite delle soglie.

La CVA classica si basa sul calcolo del vettore di cambiamento spettrale [1]: $X_D = X2 - X1$ (SCV con X2=mappa feature 2016 e X1=mappa feature 2014), già definito in precedenza. Sulla differenza e le feature selezionate si procede con una PCA a 2 componenti. Questa operazione riassume i vettori di feature a due valori dx e dy. Questi due valori sono calcolati tramite l'assunzione che la varianza maggiore sia rilevante [13] e quindi in base a questo valore calcola delle direzioni verso le quali è massima. Si trasforma la mappa dei cambiamenti in un vettore piatto e si calcola la media di esso $\bar{X}$ per ogni feature [13]. Si procede con il calcolo della matrice di covarianza (Formula 14) nella quale si studia come le diverse feature variano, andando a lavorare su dei dati centrati [13]:

$$\bar{X} = \frac{1}{p}\sum_{i=1}^{p} X_i \qquad Q = \sum_{i=1}^{p}(X_i - \bar{X})(X_i - \bar{X})^T \tag{14}$$

Dalla matrice Q estraiamo gli autovettori V, selezionando quelli che hanno valori λ_k più alti (Formula 15).

$$\mathbf{Q}\mathbf{v}_k = \lambda_k \mathbf{v}_k \qquad \mathbf{V} = [\mathbf{v}_1, \mathbf{v}_2] \tag{15}$$

Finalmente otteniamo dx e dy dalla PCA moltiplicando i valori delle feature di ogni pixel (X_i) meno la media di essi ($\bar{X}$) moltiplicando il risultato con i due vettori sopra ottenuti da V [13]:

$$dx = (X_i - \bar{X}) \cdot v_1 \qquad dy = (X_i - \bar{X}) \cdot v_2 \tag{16}$$

Con i due dx e dy dalla PCA si procede con la CVA:

- Magnitudine (ρ): rappresenta l'intensità del cambiamento calcolata tramite la distanza euclidea (Formula 17) [1].
$$\rho = \sqrt{dx^2 + dy^2} \tag{17}$$
- Direzione/Fase (ϑ): definita come la tipologia di cambiamento che viene calcolato con (Formula 18):
$$\vartheta = \arctan\left(\frac{dx}{dy}\right) \tag{18}$$
con cui si calcola il rapporto angolare tra due vettori e quindi sulla proiezione PCA dei due vettori.

Per concludere la PCA va a dare dei valori unici per ogni pixel in base ai rispettivi vettori di feature per poi portarli sul piano polare tramite magnitudine e fase riassumendoli in maniera completa e non con solo due feature.

Il risultato di questa elaborazione è uno scatterplot nello spazio polare dove vengono rappresentati i cambiamenti tramite l'angolo e la loro ampiezza che rappresenta quanto cambiano i pixel tra 2014 e 2016. Con la CVA classica abbiamo rappresentazioni a 360° in quanto l'arctan della fase restituisce angoli da π a $-\pi$ (Figura 15).
Possiamo andare poi a definire il filtro percentile (impostato a 70.2) che va a selezionare solo il 29.8 percento dei pixel in base alla magnitudo. Va di conseguenza a scartare quelli con una magnitudo bassa e tiene quelli con una magnitudo più alta, per escludere cambiamenti poco significativi nella CVA e perciò definibili come poco caratterizzanti. Questa operazione crea un buco nel mezzo del grafico, perchè appunto elimina i punti di magnitudo minore.
Un'altra tecnica di rappresentazione è la Kernel Density Estimation (KDE) per rappresentare efficentemente i picchi di densità sullo scatterplot, altrimenti non visibili perchè sovrapposti, utilizzando normalizzazioni (LogNorm e PowerNorm) per trovare i cluster più densi (Figura 15).

Un altro approccio utilizzato è quello di utilizzare una S2CVA (Sequential Spatial Change Vector Analysis), che viene utilizzata per dati iperspettrali e rende quindi possibili analisi più complete su più dimensioni [11]. Matematicamente, utilizza la SCV e calcola magnitudo (ρ) e angolo compresso (α), tramite una serie di livelli che preservano le varie informazioni dimensionali.
Inizialmente viene calcolata la magnitudo (ρ, Formula 19) che misura l'intensità del cambiamento con la distanza [11]:

$$\rho = \sqrt{\sum_{b=1}^{B} \left(X_D^b\right)^2} \tag{19}$$

dove:

- B è il numero totale di feature prese in considerazione post feature selection;
- b è l'indice di sommatoria, con $b = 1, \ldots, B$;
- X_D^b rappresenta il valore della variabile X associato al campione (o blocco) b nel dominio D;

Successivamente si passa ai procedimenti per definire una proiezione adattiva e trovare un angolo che descriva al meglio le varie feature, nel caso della S2CVA, si utilizza ASCVR (Adaptive Spectral Change Vector Representation). Si calcola un vettore di riferimento fisso, al quale poi si assegnano i valori dei pixel. Il primo passaggio è calcolare la Matrice di Covarianza (A), e da essa estrarre gli autovettori, selezionando l'autovettore con autovalore più alto (λ_k) e quindi ricavando un vettore di riferimento (V). Ottenuto il vettore di riferimento V possiamo ricavare la DAS (Distanza Angolare Spaziale, Formula 20) che si occupa di preservare la dimensionalità [11]:

$$\begin{aligned}
&\alpha_n = \arccos\left(\frac{\sum_{b=1}^{B} X_n^b V^b}{m_n \, \|V\|}\right), \qquad m_n = \|X_n\| = \sqrt{\sum_{b=1}^{B} \left(X_n^b\right)^2}, \\
&V = \left(V^1, V^2, \ldots, V^B\right) \in \mathbb{V}^B, \qquad \|V\| = \sqrt{\sum_{b=1}^{B} \left(V^b\right)^2}, \\
&\alpha_n = \begin{cases} 0, & \text{se } X_n^1 \geq 0, \\ \pi, & \text{se } X_n^1 < 0. \end{cases}
\end{aligned} \tag{20}$$

- n – indice del pixel, $n = 1, \ldots, N$
- b – indice della feature selezionata, $b = 1, \ldots, B$
- X_n^b – differenza spettrale del pixel n nella feature b

- X_n – vettore di cambiamento del pixel n (tutte le bande)
- m_n – modulo (norma) del vettore di cambiamento del pixel n
- V^b – componente b dell'autovettore principale (direzione dominante)

Questo metodo rispetto alla CVA classica occupa solo la parte superiore dello scatterplot (Figura 27) e per di più riesce a generalizzare più feature in un'analisi rendendo possibile una magnitudo dipendente da più feature e un angolo con somma pesata di più feature.

2.4 Clustering e visualizzazione spaziale dei cambiamenti

I vettori di cambiamento (Change Vector, definiti nella sezione precedente) vengono poi clusterizzati e raggruppati utilizzando un k-means con silhouette score per determinare automaticamente il numero ottimale di cluster da mostrare nello scatterplot (vedi sezione Risultati).

Il primo passaggio consiste nel mantenere solo il 30 percento dei pixel nelle zone più dense (cioè quelli la cui distanza minima dai vicini è inferiore al 30° percentile), eliminando gli outlier e stabilizzando il clustering. Possiamo poi procedere con il kmeans, selezionando dei pixel più rappresentativi dello scatterogramma, detti centroidi, e, tramite l'algoritmo nearest neighbors, usando la distanza euclidea, si calcola a quale cluster appartengono i pixel (utilizzando i centroidi di riferimento) [15]. Il numero di cluster viene definito manualmente o automaticamente dando degli intervalli (ad esempio da 3 a 7) e per ogni numero di cluster il kmeans clustering va a determinare diverse disposizioni.
Il passaggio successivo è l'utilizzo del silhouette score, che si occupa di determinare la qualità dei vari clustering. La qualità è definita come: coesione (a_i) che misura quanto un punto è vicino agli altri dello stesso cluster e separazione (b_i) che indica la distanza tra un punto e il cluster differente più vicino [17].
Nella fase finale viene poi selezionato il clustering con numero più alto sul silhouette score e che si adatta così in maniera migliore alla rappresentazione dello scatterplot.
Questa clusterizzazione è importante perché ci ha permesso di vedere come la rete e la CVA e la C2VA rappresentano tipologie diverse di cambiamento e portare tali cluster sullo scatterplot. Infatti il passaggio successivo è ricostruire l'immagine originale del 2014 tramite le patch ritagliate in precedenza e sovrapporre un overlay dove vengono rappresentati i pixel colorati e raggruppati, andando quindi a analizzare i diversi tipi di cambiamento che la rete rileva.
Il risultato è una "mappa dei cambiamenti" interpretabile grazie ai colori assegnati agli overlay di ogni cluster; viene poi applicata una sogliatura sull'ampiezza ($AMPLITUDE_TRESHOLD$) in modo da eliminare le zone con minore ampiezza di cambiamento (ρ , magnitudo) e quindi evidenziare solo i pixel maggiormente variati. Il risultato definisce:

- Posizione ed estensione dei cambiamenti rilevati.
- Diversi tipi di cambiamento (etichettati in cluster).
- Statistiche quantitative (percentuale di pixel modificati).

2.5 Architettura Shallow-net

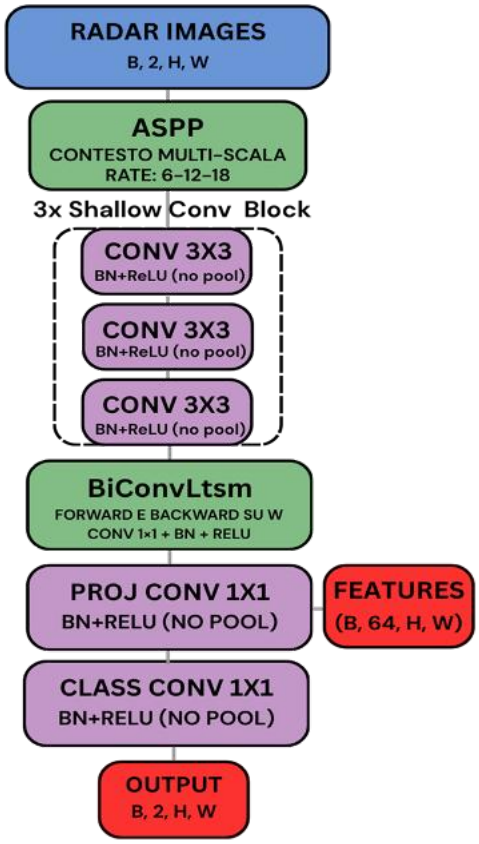


Figura 8: Architettura della Shallow-net.

La rete è formata da una shallow-net con tripla convoluzione che prende in input 2 canali, ha 64 feature e ha 2 canali di output. E' considerata una rete poco profonda (nel nostro caso ha 3 livelli) perchè è senza strati di pooling o upsampling per garantire che le feature map mantengano la risoluzione alta per localizzare i cambiamenti. Ognuno di questi blocchi esegue una convoluzione 3x3 con padding di 1, con normalizzazione e una ReLU. Queste convoluzioni sono effettuate sui risultati dell'ASPP (passo precedente nello schema), andando a marcare ancora di più le caratteristiche (pattern) delle zone. Nello specifico prendono i 9 elementi delle feature map interessati e li riassumono in maniera tale da apprendere le caratteristiche dell'immagine. Il livello di ASPP (Atrous Spatial Pyramidal Pooling) viene utilizzato per allargare il contesto dell'analisi. Utilizza queste strutture dilatate (con tassi progressivi 6, 12 e 18) che allargano il campo di ricezione senza modificare la risoluzione. Per un segnale monodimensionale x e un filtro w di lunghezza K, la formulazione matematica è espressa dalla seguente equazione (Formula 21) [3]:

$$y[n] = \sum_{k} s[n + r \cdot k] \cdot h[k] \tag{21}$$

dove i singoli termini sono definiti come segue:

- $y[n]$: rappresenta il valore del segnale in uscita (*output*) calcolato nella posizione corrente i.
- $s[n + r \cdot k]$: indica il segnale di ingresso (*input*) campionato all'indice determinato dalla posizione corrente i e dal fattore di dilatazione r. Il termine $r \cdot k$ evidenzia come il filtro non consideri elementi consecutivi, ma effettui un salto tra i campioni con un passo pari a r.
- $h[k]$: rappresenta il coefficiente del filtro (*kernel*) associato all'indice k.
- r (*dilation rate*): indica il tasso di dilatazione, ovvero il parametro che determina la distanza tra i campioni del segnale considerati dal filtro.

A seconda del valore del tasso di dilatazione r, la convoluzione (Formula 21) introduce degli intervalli regolari ed estesi, consentendo di espandere il campo preso in considerazione. Con r=1 sarebbe una semplice convoluzione e descrive cosa avviene negli strati convoluzionali della shallowCNN. Questo meccanismo permette alla rete di catturare un contesto globale e informazioni a lungo raggio senza ricorrere a reti troppo profonde, che presentano più pesi, né a pooling [3].
Quindi prende l'immagine a un livello più ampio, non singolarmente a livello di pixel, riconoscendo pattern e continuità dei cambiamenti nel substrato.
Nella ricerca le ASPP vengono utilizzate anche in campo medico e dei modelli generativi, portando miglioramenti e abbassando i requisiti perché diminuiscono lo spazio occupato dalla rete (con capacità simili) [3].

La stratigrafia del ghiaccio può essere riconosciuta orizzontalmente sull'immagine (Figura 1), in quanto non è rappresentata da singoli pixel ma ha forte continuità, infatti, due colonne vicine sono molto simili tra loro e perciò solo pochi elementi cambiano. Una BiConvLSTM (Bidirectional Convolutional Long Short-Term Memory) si occupa di interpretare l'immagine intera ad una visione sequenziale di colonne verticali lungo la traccia di volo del radar [4]. Nello specifico ha un segnale continuo lungo le diverse colonne, mantenendo così la coerenza tra le diverse patch prese in considerazione. Oltre a ciò rende l'analisi resistente al rumore in quanto

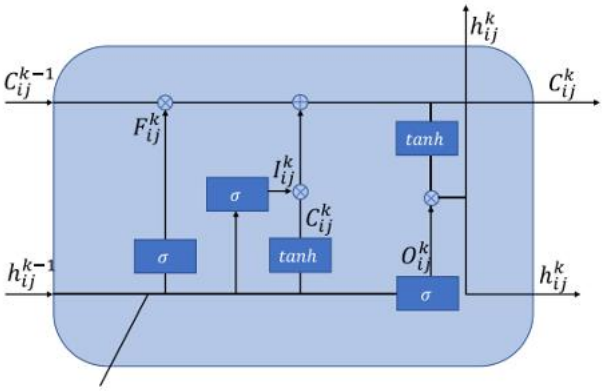


Figura 9: Modulo LSTM [9].

non è localizzata (ad esempio, un pixel rumoroso rovina l'analisi) ma si concentra su come lo strato si evolve. Il fatto che sia bidirezionale indica la duplice operazione: forward e backward. Questi due passaggi permettono di correlare una colonna sia alla precedente (forward) sia alla successiva (backward) e, di conseguenza, ottenere una cattura in entrambe le direzioni [4].
A differenza delle classiche LSTM che usano operatori scalari, la LSTM convoluzionale aggiunge operatori di convoluzione per analizzare immagini (nel nostro caso radargrammi) [9]. Questo permette alle colonne di mantenere la loro integrità spaziale, perchè la LSTM classica ridurrebbe le colonne a uno scalare. In aggiunta, permette di trovare caratteristiche sulle singole colonne. Definendo quindi la metodologia di questa operazione, l'immagine viene divisa in colonne $(C, H, 1)$ e processata in due direzioni opposte. Con le mappe di entrambe le direzioni interviene una convoluzione 1x1 che ha il compito di fondere le mappe riducendo la dimensionalità (Formula 22):

$$\text{Output} = \text{Conv}_{1\times1}([\text{fwd_map} \parallel \text{bwd_map}]) \tag{22}$$

Successivamente, l'output passa da $(2C, H, W)$ a (C, H, W) dopo la fusione. Le LSTM sono varianti delle RNN (Rete neurale ricorrente) dotate di una cella di memoria composta da due stati distinti e tre porte moltiplicative che regolano i flussi di informazione [9].

La memoria è contenuta in due vettori di stato: stato a lungo termine (c_t), che descrive le caratteristiche lungo l'intera sequenza, e a breve termine (h_t), che descrive il passo temporale corrente e quindi alla prossima colonna verrà aggiornato [4] [9]. Le tre porte (gates) regolano il modo in cui le informazioni vengono formulate e, nel caso della Forget gate, permettono di dimenticare (f_t, Formula 23) [9]: analizzano l'input attuale (x_t) e lo stato precedente (h_{t-1}) per determinare le informazioni da eliminare dalla memoria a lungo termine (c_{t-1}).

$$f_t = S(W_{xf}x_t + W_{hf}h_{t-1} + W_{cf}c_{t-1} + b_f) \tag{23}$$

Dove la funzione sigma S con 0 dimentica e con 1 ricorda, mentre W sono i pesi e b i bias della rete.

Poi abbiamo l'Input gate (i_t, Formula 24) che decide cosa aggiungere alla memoria a lungo termine [9]:

$$i_t = S(W_{xi}x_t + W_{hi}h_{t-1} + W_{ci}c_{t-1} + b_i) \tag{24}$$

L'input gate ha le stesse variabili definite nella forget gate. Contemporaneamente per ogni colonna si effettua la creazione di un nuovo candidato $(\bar{c}_t)$ con le informazioni trasformate:

$$\bar{c}_t = \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c) \tag{25}$$

Dove l'arcotangente tra -1 e 1 determina l'intensità di aggiornamento. Dopo questa operazione si aggiorna la memoria a lungo termine con le informazioni da eliminare dall'output della forget gate e aggiunte dall'input gate [9]:

$$c_t = f_t c_{t-1} + i_t \bar{c}_t \tag{26}$$

dove la somma che permette all'informazione di fluire lungo le colonne.
Abbiamo poi la Output gate (o_t) che decide quali parti della memoria a lungo termine verranno inserite nella memoria a breve termine [9]:

$$o_t = S(W_{xo} * x_t + W_{ho} * h_{t-1} + b_o), h_t = o_t \tanh(c_t) \tag{27}$$

Dopo questi layer che determinano le feature possiamo definire gli ultimi due come terminali e funzionali. Il prossimo layer è detto di proiezione (proj layer) ed è una Conv 1x1 seguita da normalizzazione e ReLU, che è il blocco di estrazione delle features e restituisce le feature map (nel nostro caso 64 canali). Un layer identico è applicato al termine ed è detto classifier perchè riporta i canali da 64 a 2, come nell'input consentendo all'immagine originale di essere ricostruita come output.

Descrizione del dataset

Il dataset è un insieme di radargrammi acquisiti con un radar sounder in Antartide in due campagne distinte: una condotta dal 3-4 novembre 2014 e l'altra dal 3-6 novembre 2016. (Figura 10)

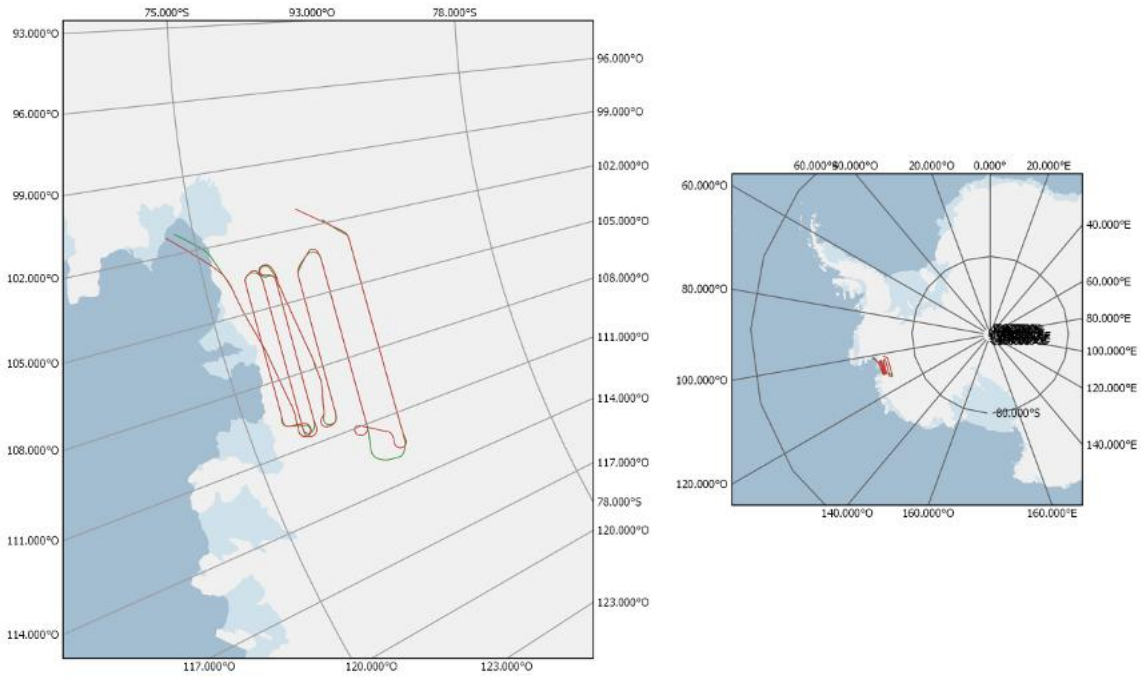


Figura 10: Tracce delle campagne 2014103-04 in rosso e 2016103-06 in verde. [6]

I dataset contengono delle immagini radar post-processate che hanno subito compressione della distanza, focalizzazione SAR in azimut e beamforming. In aggiunta, si normalizzano queste acquisizioni radar in modo da non ottenere differenze sull'analisi che sarebbero determinate dal rollio dell'aereo sulle curve, che porta a cambiamenti nell'onda riflessa. Vengono anche mascherate tutte le informazioni sopra la superficie per ottenere più segnale riguardante i sottostrati glaciali. Questi dati provengono da sensori sviluppati dall'Università del Kansas: MCoRDS-3, con i seguenti parametri per l'acquisizione [6]:

Parametri	**Dataset Antartide**
Frequenza centrale	190 MHz
Lunghezza d'onda	1,58 m
Larghezza di banda	50 MHz
Frequenza di campionamento	50 MHz
Potenza trasmessa	6 kW
Altitudine AGL	0,5 km
Risoluzione in distanza nel ghiaccio	2,6 m
Risoluzione in azimut	27,5 m
Distanza di campionamento al suolo	15 m

Il preprocessing ha riscontrato diversi problemi che hanno necessitato una precisa co-registrazione [7]:

- Sovrapposizione parziale delle impronte radar (Figura 11).
- Differenze nella lunghezza delle traiettorie e nel posizionamento esatto.
- Spostamenti attesi dovuti al flusso glaciale (principalmente orizzontale) e ai cambiamenti di massa superficiali/sottosuperficiali (verticali).

3.1 Preprocessing, allineamento e pipeline di co-registrazione

La co-registrazione è a priori una fase fondamentale perchè fase iniziale della pipeline operativa sui radargrammi e permette di lavorare su segmenti correttamente allineati.

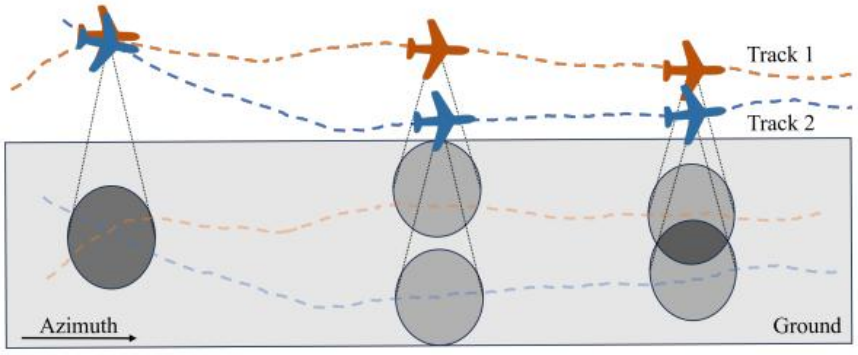


Figura 11: Geometria di acquisizione di due tracce e delle loro impronte. Da sinistra, le impronte sono completamente sovrapposte, non sovrapposte e parzialmente sovrapposte. [7]

Il primo procedimento consiste nell'assicurarsi che i radargrammi rappresentino la stessa porzione di ghiacciaio e che le loro coordinate GPS (latitudine e longitudine) siano corrispondenti: le tracce aeree seguite dal velivolo vengono analizzate sia verticalmente che orizzontalmente, in modo da capire quando le footprint dell'antenna sono corrispondenti tra i due anni mentre le parti non coincidenti non vengono considerate.
Per eliminare ciò che viene rilevato sopra al ghiacciaio si procede alla normalizzazione della potenza, in funzione della potenza rilevata in superficie, in modo da concentrarsi sugli strati inferiori della calotta e non sulla parte sovrastante al ghiacciaio.
Si procede poi con l'utilizzo del Dynamic Time Warping (DTW), che consiste nel proiettare un radargramma più ampio (slave) su uno più ristretto (master) riconoscendo quali sequenze corrispondono spazialmente andando a fare delle vere e proprie corrispondenze e di conseguenza allineandolo.
Successivamente si procede con la co-registrazione (grossolana) utilizzando la bedrock (roccia basale) come riferimento fisso per far corrispondere in direzione dell'azimuth (orizzontale) ma anche verso la profondità (verticale) i due radargrammi (per questo passaggio si utilizza la roccia basale perchè si suppone che nel tempo sia un elemento stabile e invariato). Per via delle varie proprietà dielettriche e velocità di spostamento dei vari strati del ghiacciaio dividiamo in sezioni orizzontali (Figura 12) il radargramma: top ice (superficie/firn), middle ice, basal ice e bedrock [6]. La divisione verticale (Figura 12) è fondamentale per allineare al meglio ogni zona

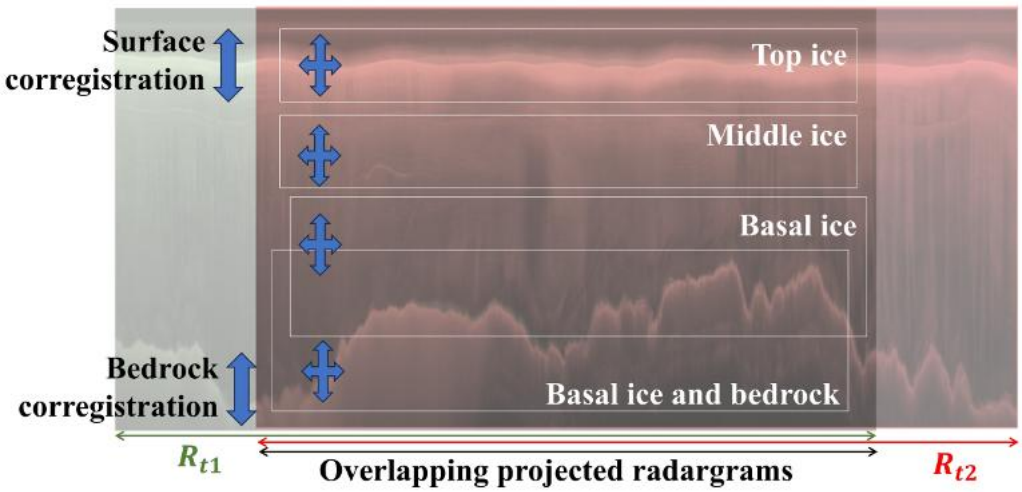


Figura 12: Correlazione incrociata dei radargrammi Rt1 in verde e Rt2 in rosso: i riquadri bianchi indicano i quattro sotto-radargrammi che vengono correlati separatamente, e le frecce blu indicano le direzioni della correlazione incrociata [6].

in quanto ognuna di queste subisce uno slittamento e variazioni verticali negli strati. La sezione superiore ha

velocità di slittamento maggiore e spostamento verticale maggiore rispetto allo strato bed (partendo dalla velocità massima in superficie scendendo verso il bed diminuiscono). Se manteniamo il radargramma intero sarebbe una rappresentazione imprecisa e si dividono dunque i radargrammi in porzioni diverse di ghiaccio in base alla zona o profondità. Fatto questo, si dovrebbe riuscire a co-registrare al meglio ogni sezione del ghiacciaio per mitigare questi movimenti naturali, chiamati cambiamenti attesi, e procedere nella ricerca dei cambiamenti inattesi. Dopo questa frammentazione si procede con una co-registrazione localizzata che va ad analizzare tramite correlazione varie patch. Questa operazione può essere di più tipi:

- Cross-correlazione non coerente (basata sull'ampiezza).
- Cross-correlazione coerente (che utilizza valori complessi, preservando l'informazione di fase).

Possiamo descrivere l'approccio coerente come migliore in quanto includendo la fase otteniamo molte più informazioni intrinseche nell'onda riflettuta rispetto alla sola ampiezza.
La correlazione più precisa per quanto riguarda i radargrammi è rappresentata dalla cross-correlazione coerente normalizzata (Formula 28) [6] in quanto osserva più la struttura del radargramma e meno le intensità, compensando le differenze di potenza e ampiezza, così da essere più oggettiva. Il massimo valore di correlazione rappresenta la migliore corrispondenza tra i due radargrammi, evidenziando le aree di maggiore somiglianza strutturale:

$$\gamma(h', w') = \frac{\sum_{(h,w)} \left[R^s_{t_1}(h,w) - \overline{R^s_{t_1}} \right] \left[R^s_{t_2}(h-h', w-w') - \overline{R^s_{t_2}} \right]}{\sqrt{\sum_{(h,w)} \left[R^s_{t_1}(h,w) - \overline{R^s_{t_1}} \right]^2 \sum_{(h,w)} \left[R^s_{t_2}(h-h', w-w') - \overline{R^s_{t_2}} \right]^2}} \tag{28}$$

dove:

- $\gamma(h', w')$ rappresenta il coefficiente di cross-correlazione normalizzata associato allo spostamento (h', w');
- $R^s_{t_1}(h,w)$ e $R^s_{t_2}(h,w)$ rappresentano i campioni del radargramma acquisiti agli istanti t_1 e t_2, rispettivamente, nella striscia s;
- s identifica la regione o la striscia del radargramma analizzata (ad esempio top ice, middle ice, basal ice, basal interface);
- h rappresenta la coordinata nella direzione di range;
- w rappresenta la coordinata nella direzione di azimuth;
- h' rappresenta lo spostamento nella direzione di range;
- w' rappresenta lo spostamento nella direzione di azimuth;
- $\overline{R^s_{t_1}}$ e $\overline{R^s_{t_2}}$ rappresentano i valori medi calcolati sulle corrispondenti finestre dei radargrammi.

Tramite questa formula è possibile spostare in maniera libera il frammento dello slave (citato nel DTW) efficacemente da far aumentare il valore della cross-correlazione e quindi ottenere immagini combacianti.
Dopo quest'ultimo allineamento interviene l'operatore log-ratio (Formula 29) [7] che viene usato per valutare la qualità della co-registrazione:

$$\mathcal{L}(h,w) = \log\left(\frac{|\hat{R}_{2014}(h,w)|}{|R_{2016}(h,w)|} \right) \tag{29}$$

dove:

- $\mathcal{L}(h,w)$ rappresenta il valore dell'operatore log-ratio calcolato nella posizione (h,w);
- $\hat{R}_{2014}(h,w)$ rappresenta il campione del radargramma acquisito nel 2014 dopo l'applicazione della procedura di co-registrazione;

- $R_{2016}(h, w)$ rappresenta il campione del radargramma acquisito nel 2016 utilizzato come riferimento;

Questa mappa evidenzia eventuali disallineamenti dettati da alti valori di log-ratio in modo da poter identificare grossi disallineamenti e andare quindi a aggiustare il risultato e riprocedere con la correlazione.

3.2 Divisione in patch

I vari radargrammi co-registrati sono divisi in patch da 256 pixel orizzontali con offset di 128 per consentire un'analisi più focalizzata e mantenere le fasi di train gestibili a livello di memoria, altrimenti essendo radargrammi molto grandi andremmo out-of-memory. Queste patch rappresentano appunto stesse porzioni di spazio ma in due differenti momenti, sia 2014 che 2016.
Queste patch vengono poi normalizzate (media zero, varianza unitaria) per uniformizzarle e essere convertite e utilizzate in formato .npy. Per facilitare il rilevamento e il test dei metodi di analisi, è possibile selezionare manualmente delle zone dove si nota un cambiamento rilevante.

Risultati

Per valutare i risultati consideriamo delle aree dove ci sono dei cambiamenti nel radargramma. Viene inoltre fatto un confronto di combinazioni sia sulle tecniche di selezione feature che con un diverso tipo di analisi del vettore di cambiamento (CVA), oppure con un cambiamento della rete. Gli user case utilizzati sono due segmenti di radargramma uno rappresentante un cambiamento di stratigrafia e l'altro presenta una parte inferiore, che rappresenta i cambiamenti in zona basale.

CASI ANALIZZATI

GHIACCIO CENTRALE (Figura 13)

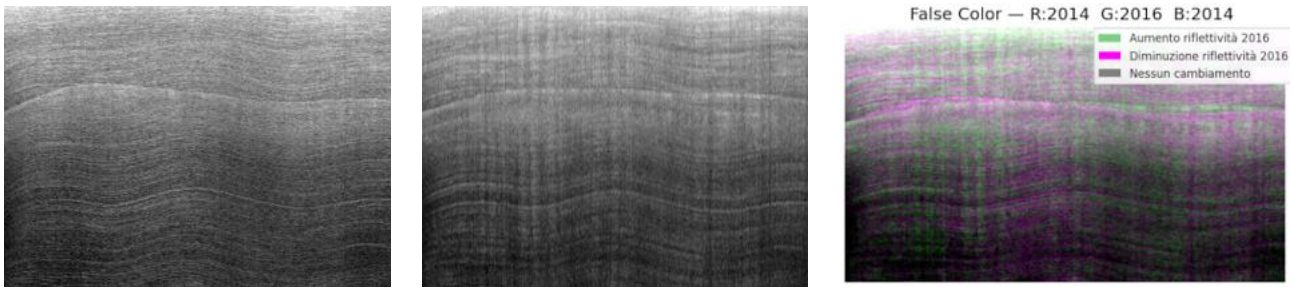


Figura 13: (a) Radargramma nel 2014, (b) radargramma nel 2016 e (c) rappresentazione in falso colore della stessa area, utilizzata per evidenziare i cambiamenti.

GHIACCIO BASALE (Figura 14)

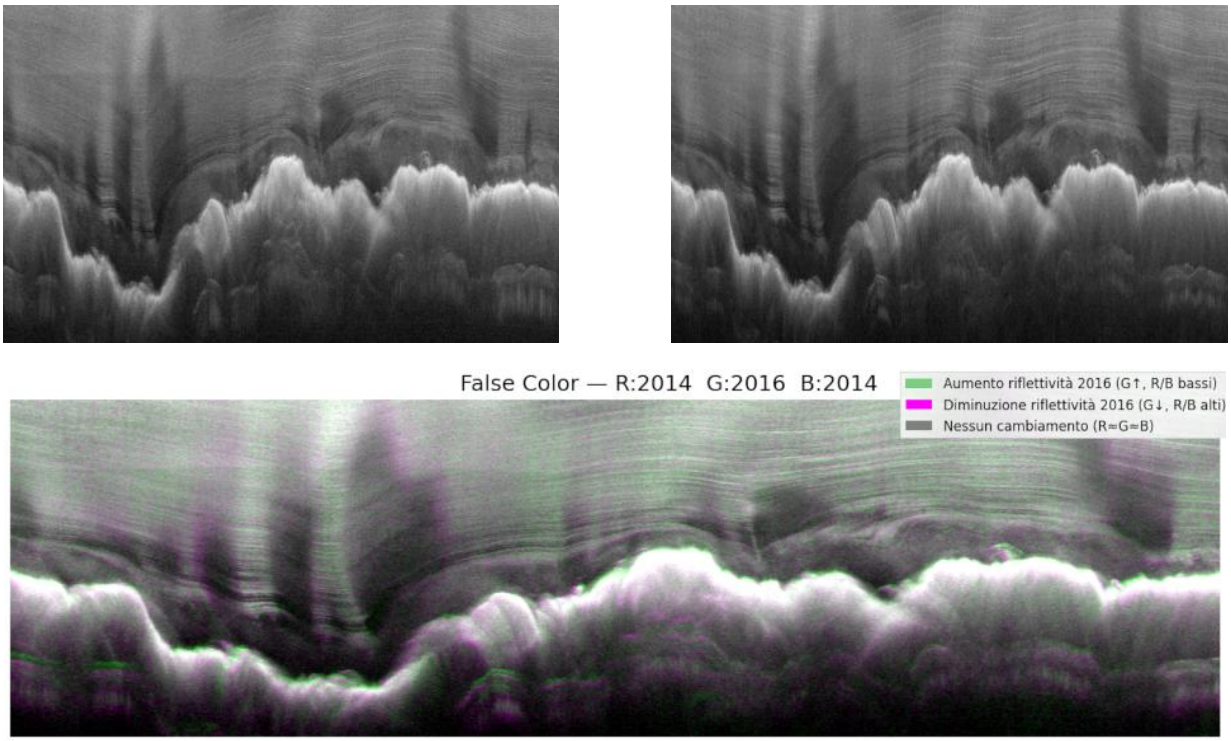


Figura 14: (a) Radargramma nel 2014, (b) radargramma nel 2016 e (c) rappresentazione falso colore in modo da notare i cambiamenti. Patch estratta da un radargramma del dataset in una zona inferiore rappresentante cambio di stratigrafia.

4.1 Modifiche sulla rete

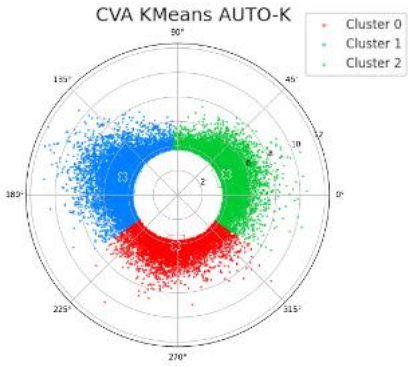
Al variare della rete possiamo notare che otteniamo risultati diversi. Ogni blocco va a modificare il modo nel quale le feature vengono estratte e di conseguenza ne determina delle caratteristiche.
Facendo riferimento al capitolo 2.5 – *Architettura Shallow – net* possiamo osservare la struttura della rete finale ma per rilevare differenze nel modo nel quale vengono estratte le feature in base alla struttura sono stati effettuati dei test su diverse reti. Gli esperimenti sono stati fatti con una semplice shallow-net, successivamente una shallow-net+ASPP e infine si inserisce un blocco BiConvLSTM diventando shallow-net+ASPP+LSTM e finalmente si possono effettuare dei confronti (Figura 8).
Per di più anche la modifica della funzione di loss va a influire sulle feature e sui risultati finali: sono stati effettuati allenamenti sia con la tv loss che senza. Di base la funzione di loss è una MSE (mean squared error).
Per standardizzare il processo seguente viene utilizzata una selezione per VARIANZA con PCA e una CVA, con inoltre il filtro sull'ampiezza impostato a 1 altrimenti sarebbero molti più i pixel rilevati come cambiati.

STRUTTURA DELLE RETI TESTATE

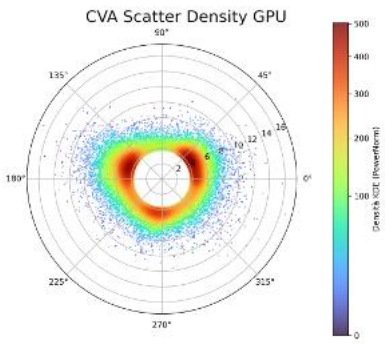
Le caratteristiche delle reti testate:

- ESPERIMENTO 1: SHALLOW-CNN semplice senza aggiunte solo 3 convoluzioni con allenamento MSE semplice;
- ESPERIMENTO 2: SHALLOW-CNN con aggiunta una ASPP (Atrous Spatial Pyramid Pooling) con un allenamento MSE + tv loss;
- ESPERIMENTO 3: SHALLOW-CNN con aggiunta una ASPP (Atrous Spatial Pyramid Pooling) con un allenamento MSE semplice;
- ESPERIMENTO 4: SHALLOW-CNN con aggiunta una ASPP (Atrous Spatial Pyramid Pooling) e una BiConvLSTM (Bi Convolutional Long Short Term Memory) con un allenamento MSE + tv loss;
- ESPERIMENTO 5: SHALLOW-CNN con aggiunta una ASPP (Atrous Spatial Pyramid Pooling) e una BiConvLSTM (Bi Convolutional Long Short Term Memory) con un allenamento MSE semplice.

ESPERIMENTO 1: GHIACCIO CENTRALE (Figura 15)



(a) Scatter con cluster



(b) Scatter con densità KDE

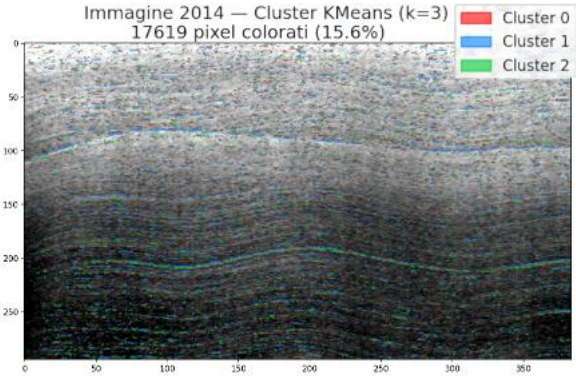
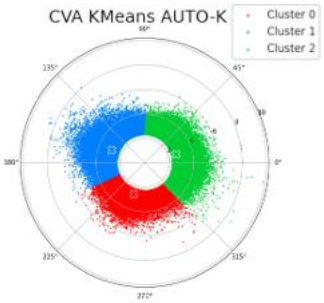
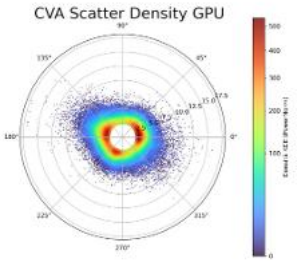


Figura 15: Risultati SHALLOW-CNN per ghiaccio centrale: (a) clustering nello spazio CVA, (b) densità KDE e overlay dei pixel cambiati sul radargramma 2014.

ESPERIMENTO 1: GHIACCIO BASALE (Figura 16)



(a) Scatter con cluster



(b) Scatter con densità KDE

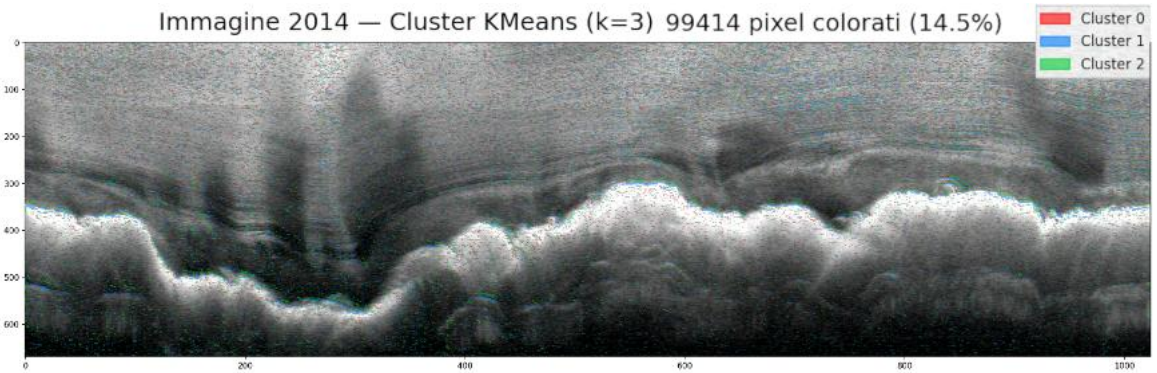
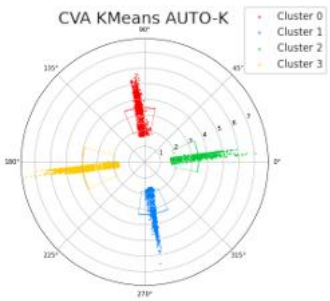
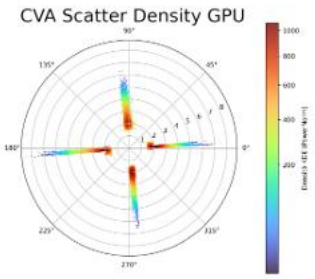


Figura 16: Risultati SHALLOW-CNN per ghiaccio basale: (a) clustering nello spazio CVA, (b) densità KDE e (c) overlay dei pixel cambiati sul radargramma 2014.

ESPERIMENTO 2: GHIACCIO CENTRALE(Figura 17)



(a) Scatter con cluster



(b) Scatter con densità KDE

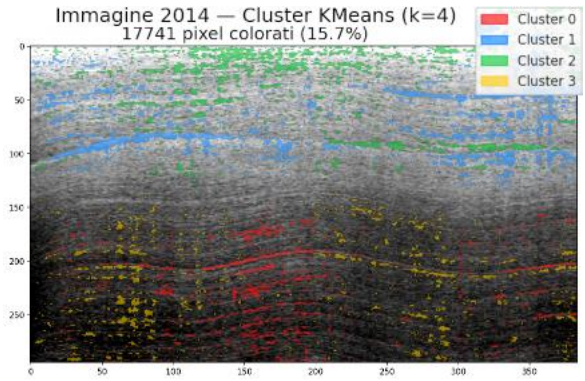
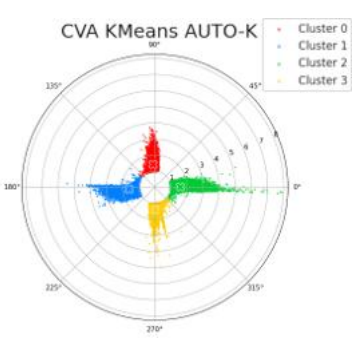
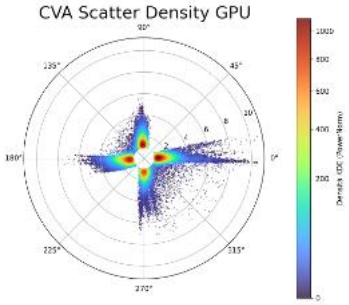


Figura 17: Risultati ASPP + SHALLOW-CNN (Train MSE + TVLOSS) per ghiaccio centrale: (a) clustering nello spazio CVA, (b) densità KDE e (c) overlay dei pixel cambiati sul radargramma 2014.

ESPERIMENTO 2: GHIACCIO BASALE (Figura 18)



(a) Scatter con cluster



(b) Scatter con densità KDE

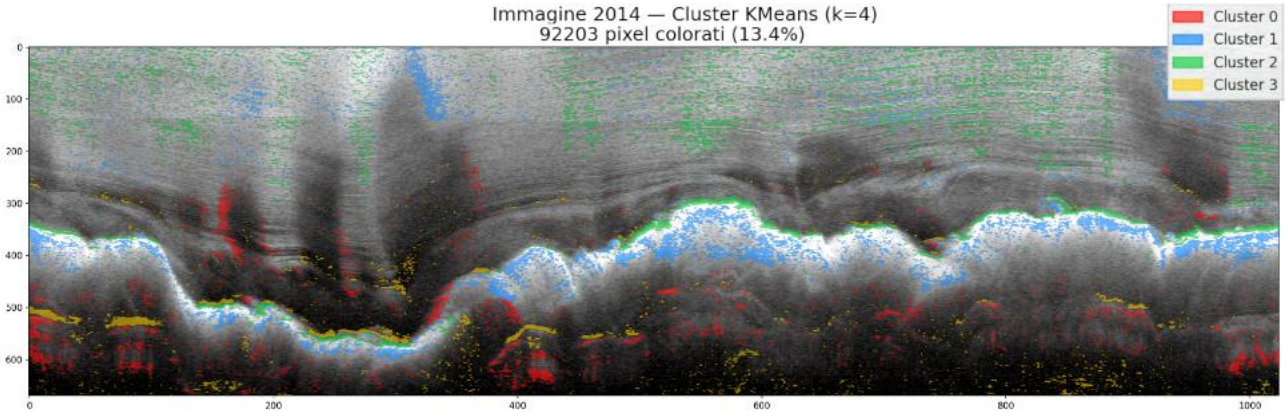
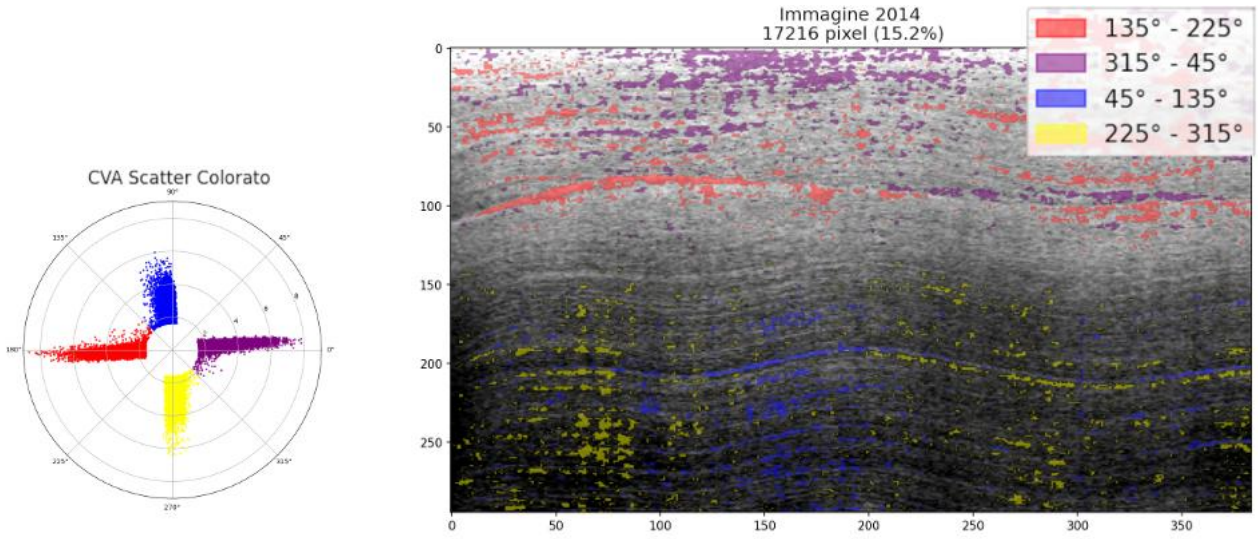


Figura 18: Risultati ASPP + SHALLOW-CNN (Train MSE + TVLOSS) per ghiaccio basale: (a) clustering nello spazio CVA, (b) densità KDE e (c) overlay dei pixel cambiati sul radargramma 2014.

Possiamo determinare che l'aggiunta dell'ASPP migliora la definizione in aree di cambiamento come avviene negli esempi della rappresentazione a falso colore dando maggiore continuità e pienezza al risultato. Possiamo determinare che anche i pixel sparsi riconosciuti come cambiamento vengono eliminati e non coinvolti. Guardando gli scatterplot possiamo notare invece il cambiamento di disposizione in quanto la ASPP rende più facile per la CVA la divisione in cluster.

ESPERIMENTO 3: GHIACCIO CENTRALE (Figura 19)



(a) Scatter con cluster (b) Overlay su radargramma del 2014

Figura 19: Risultati ASPP + SHALLOW-CNN (Train solo MSE) per ghiaccio centrale: (a) clustering nello spazio CVA e (b) overlay dei pixel cambiati sul radargramma 2014.

ESPERIMENTO 3: GHIACCIO BASALE (Figura 20)



(a) Scatter con cluster (b) Scatter con densità KDE

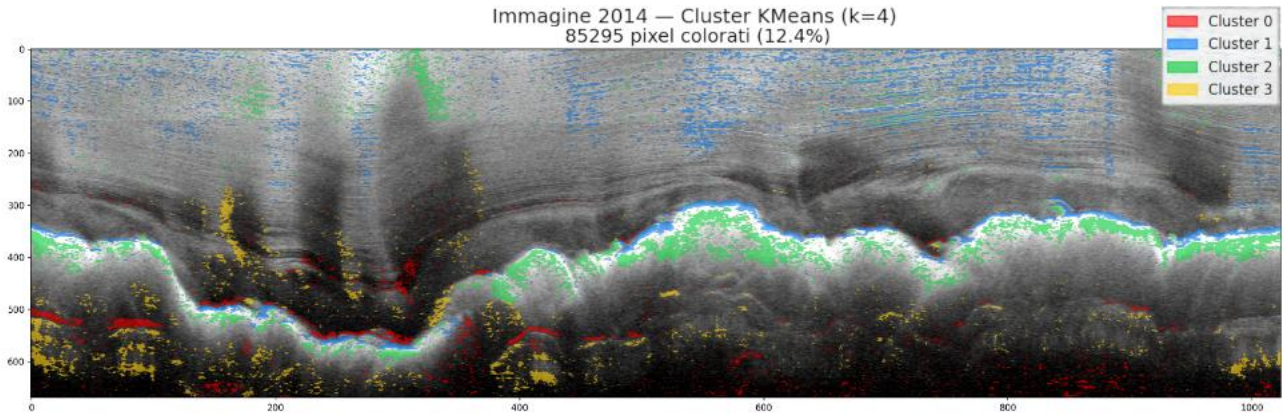
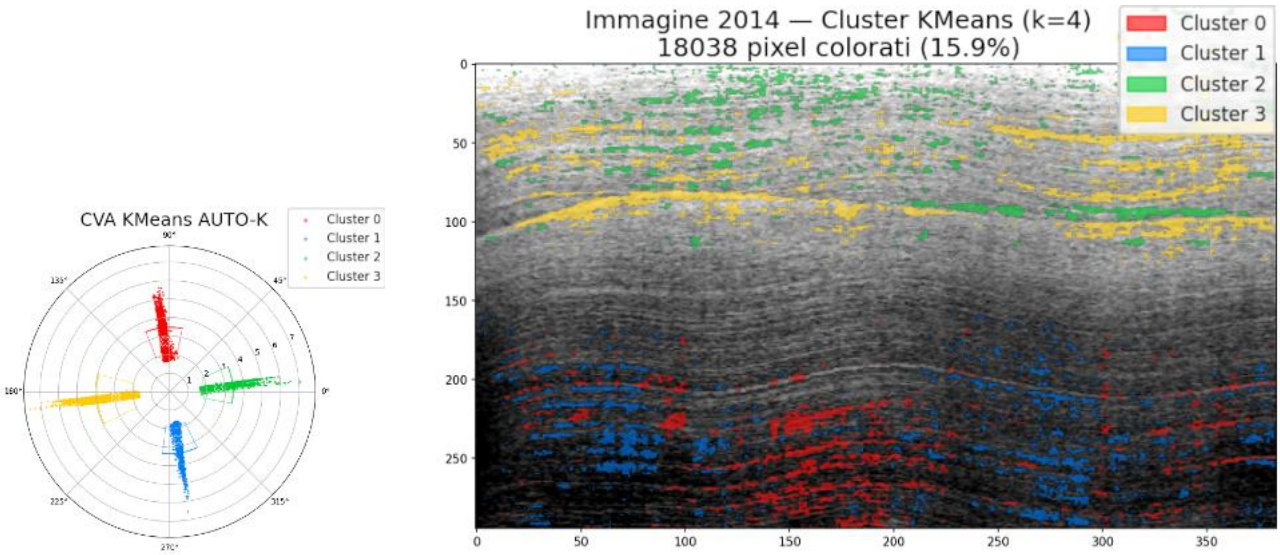


Figura 20: Risultati ASPP + SHALLOW-CNN (Train solo MSE) per ghiaccio basale: (a) clustering nello spazio CVA, (b) densità KDE e (c) overlay dei pixel cambiati sul radargramma 2014.

Possiamo definire che le differenze tra il train con tv loss (ESPERIMENTO 2) e il train senza tv loss (ESPERIMENTO 3) non determina miglioramenti nella definizione dei cluster o dei cambiamenti ma lascia i risultati pressochè identici.

ESPERIMENTO 4: GHIACCIO CENTRALE (Figura 21)



(a) Scatter con cluster

(b) Overlay su radargramma del 2014

Figura 21: Risultati LSTM + ASPP + SHALLOW-CNN (Train MSE + TVLOSS) per ghiaccio centrale: (a) clustering nello spazio CVA e (b) overlay dei pixel cambiati sul radargramma 2014.

ESPERIMENTO 4: GHIACCIO BASALE (Figura 22)



(a) Scatter con cluster

(b) Scatter con densità KDE

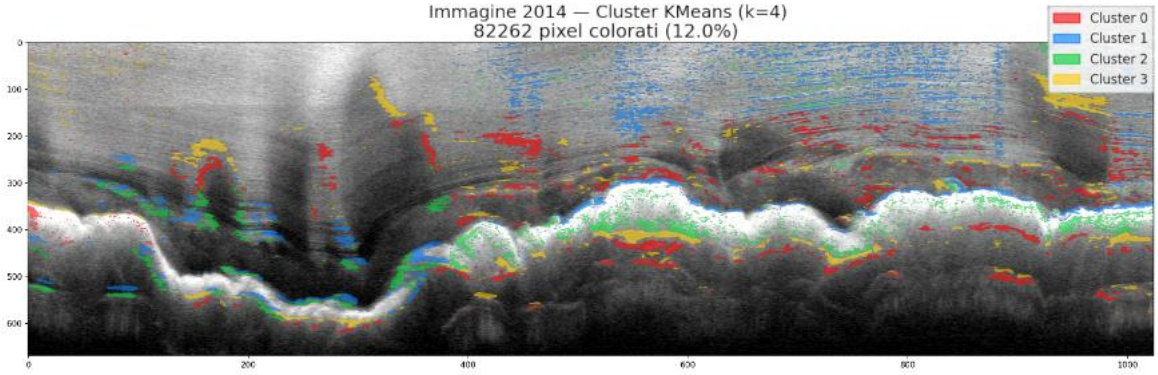
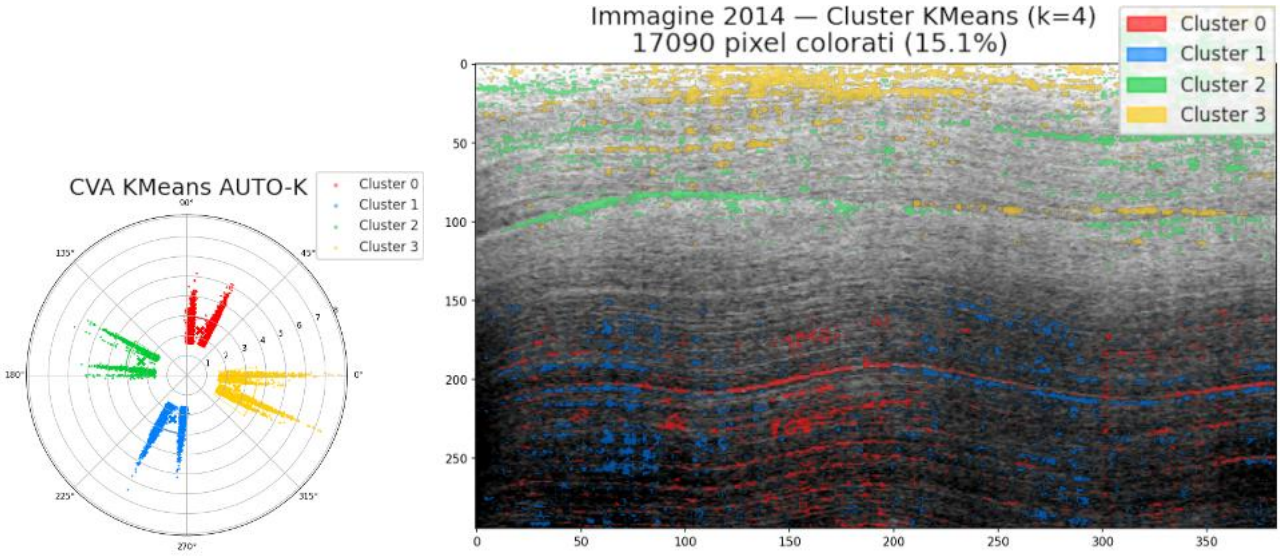


Figura 22: Risultati LSTM + ASPP + SHALLOW-CNN (Train MSE + TVLOSS) per ghiaccio basale: (a) clustering nello spazio CVA, (b) densità KDE e (c) overlay dei pixel cambiati sul radargramma 2014.

I risultati con l'aggiunta della LSTM sono maggiormente focalizzati sui cambiamenti e migliorano l'isolamento delle aree togliendo ulteriormente pixel sparsi.

ESPERIMENTO 5: GHIACCIO CENTRALE (Figura 23)

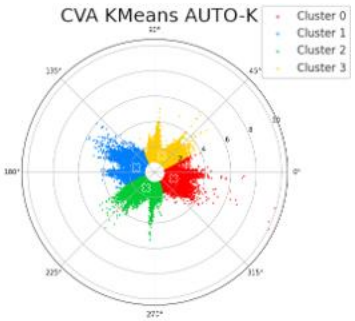


(a) Scatter con cluster

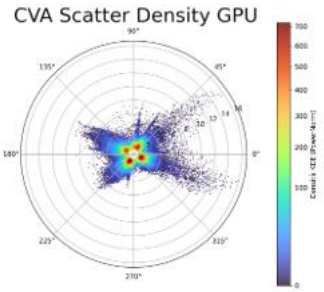
(b) Overlay su radargramma del 2014

Figura 23: Risultati LSTM + ASPP + SHALLOW-CNN (Train solo MSE) per ghiaccio centrale: (a) clustering nello spazio CVA e (b) overlay dei pixel cambiati sul radargramma 2014.

ESPERIMENTO 5: GHIACCIO BASALE (Figura 24)



(a) Scatter con cluster



(b) Scatter con densità KDE

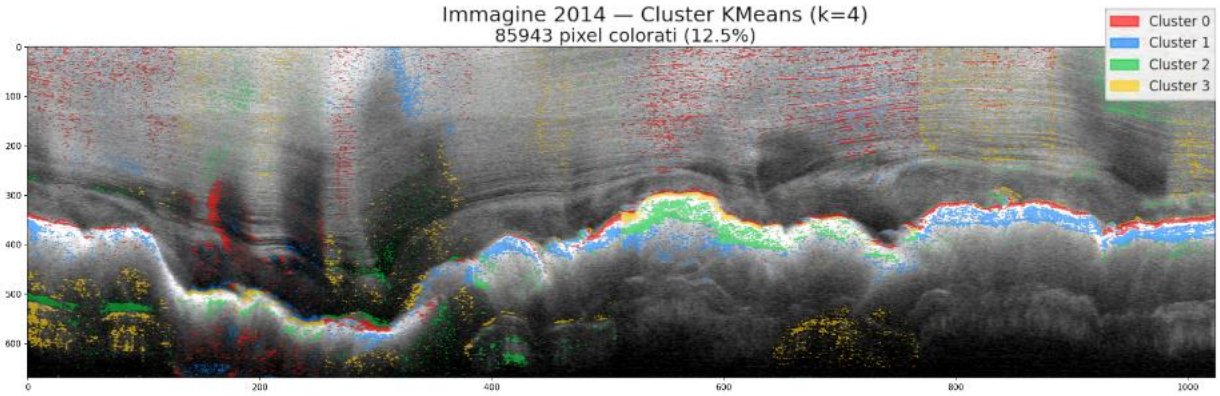


Figura 24: Risultati LSTM + ASPP + SHALLOW-CNN (Train solo MSE) per ghiaccio basale: (a) clustering nello spazio CVA, (b) densità KDE e (c) overlay dei pixel cambiati sul radargramma 2014.

La mancanza della tv loss si riflette nei risultati in quanto presentano meno unità e solidità nei cluster e la tv loss (ESPERIMENTO 8) sembra migliorare ulteriormente i rilevamenti dei cambiamenti stratigrafici in direzione orizzontale.

4.2 Modifiche nella CVA

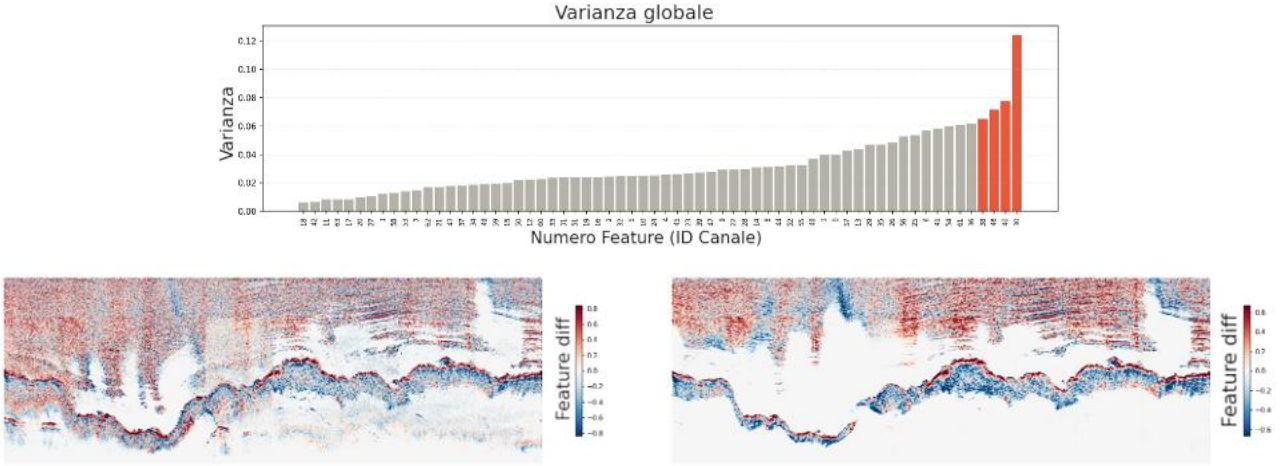
Oltre alle valutazioni effettuate sui vari tipi di rete, sono stati effettuati dei test con dei cambiamenti sui metodi di selezione delle feature e tipologia di analisi dei vettori di differenza (SCV) come definito nella sezione Metodologia.
Per quanto riguarda la scelta delle feature sono stati utilizzati VARIANZA e SSIM, come spiegato nella Metodologia. Inoltre sono stati selezionati due approcci per la rappresentazione e divisione sugli scatterplot: PCA+CVA e S2CVA, che ne determina un utilizzo completo dello scatter o parziale solo con la metà superiore. Sono state utilizzate lo stesso tipo di feature estratte da una ASPP+Shallow-net (solo MSE, no tv loss) in modo da osservare come questi strumenti influenzano i risultati selezione e diversa distribuzione sullo scatter. Le feature map sono i valori per quel specifico canale su ogni pixel (che vengono selezionate) e sono mostrate per comprendere come avviene la selezione delle feature.

STACK UTILIZZATI

Gli stack di strumenti utilizzati sono definiti come:

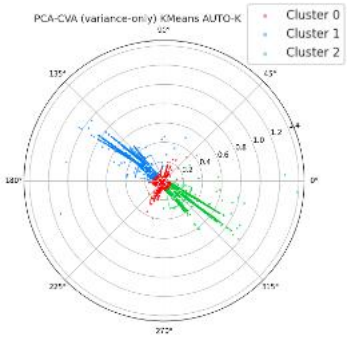
- ESPERIMENTO 6: selezione di VARIANZA con un'applicazione di PCA e CVA per le feature selezionate;
- ESPERIMENTO 7: selezione di VARIANZA e SSIM con un'applicazione di PCA e CVA per le feature selezionate;
- ESPERIMENTO 8: selezione di VARIANZA con un'applicazione di S2CVA per le feature selezionate;
- ESPERIMENTO 9: selezione di VARIANZA e SSIM con un'applicazione di S2CVA per le feature selezionate;

ESPERIMENTO 6: GHIACCIO BASALE (Figura 25)

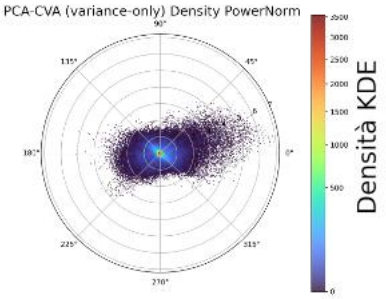


(a) Feature map 30

(b) Feature map 38



(c) Cluster



(d) Densità KDE

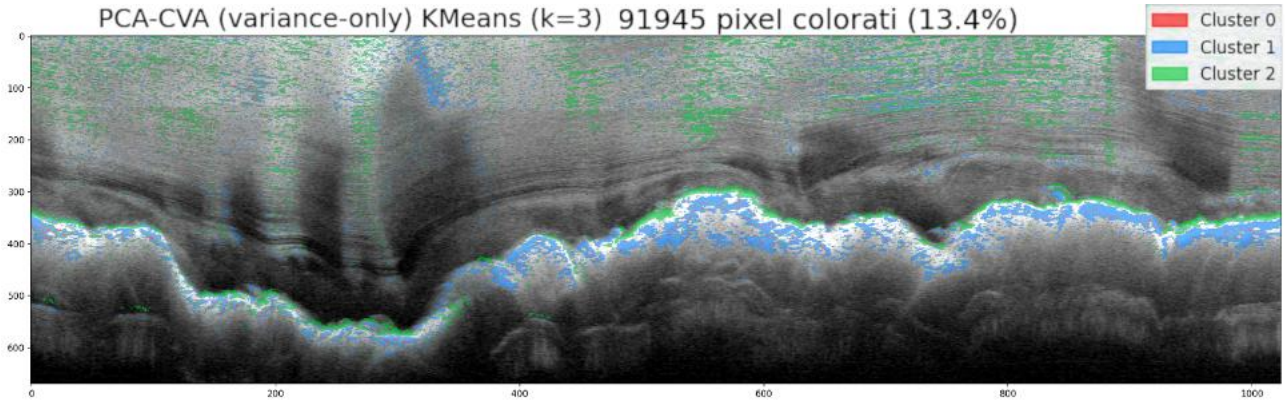
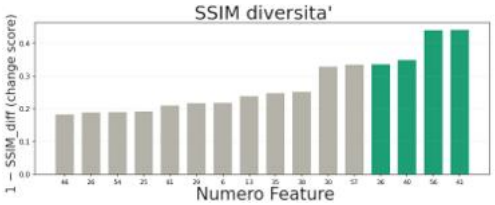


Figura 25: Istogramma della varianza, feature selezionate rappresentate nell'istogramma della varianza (feature 30, 40, 46 e 38), clustering nello spazio PCA-CVA e overlay dei pixel cambiati.

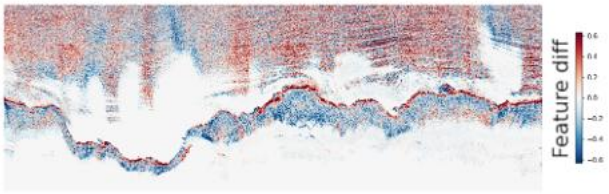
ESPERIMENTO 7: GHIACCIO BASALE (Figura 26)



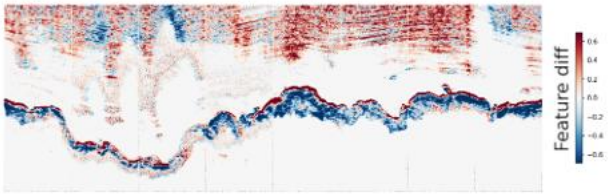
(a) Istogramma della varianza



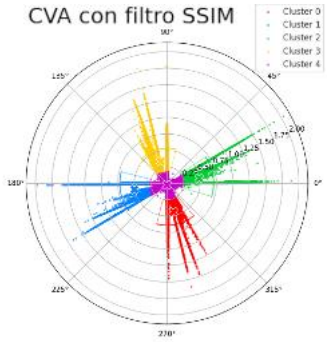
(b) Istogramma della SSIM



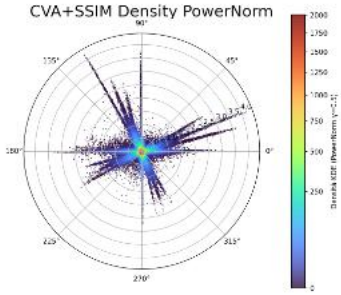
(c) Feature map 36



(d) Feature map 40



(e) Cluster



(f) Densità KDE

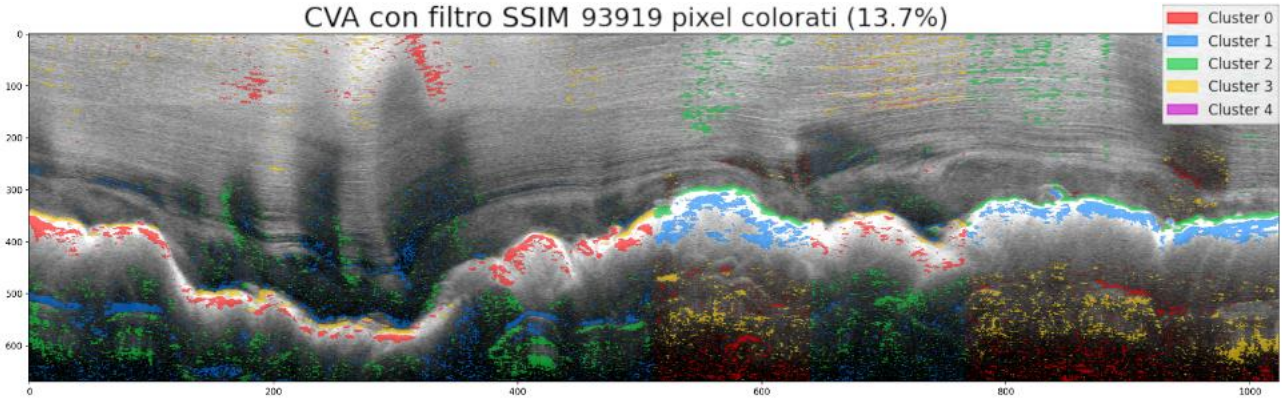
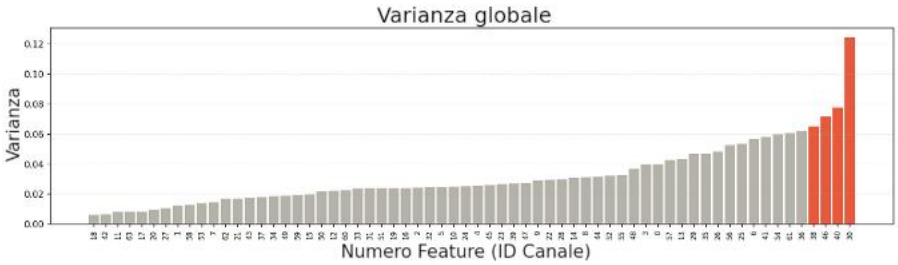
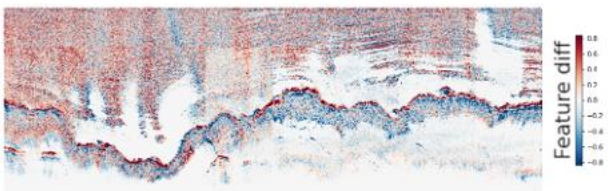


Figura 26: Istogrammi della varianza e della SSIM (feature 41, 56, 40 e 36), feature map selezionate, clustering nello spazio CVA-SSIM e overlay dei pixel cambiati.

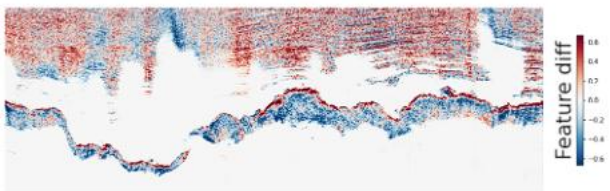
La clusterizzazione è molto migliore nell'ESPERIMENTO 7 dove la SSIM va a selezionare feature map uniche e maggiormente differenziate e marcate permettendo una migliore identificazione dei cambiamenti.

ESPERIMENTO 8: GHIACCIO BASALE (Figura 27)

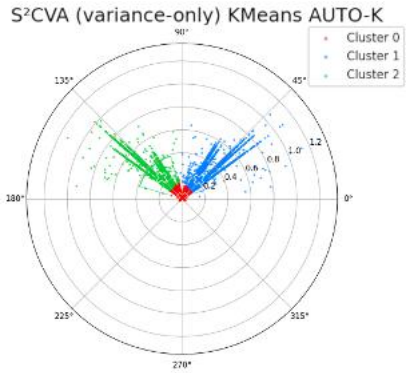




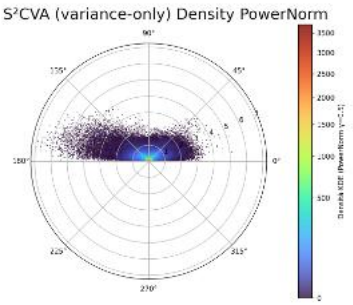
(a) Feature map 30



(b) Feature map 38



(c) Cluster



(d) Densità KDE

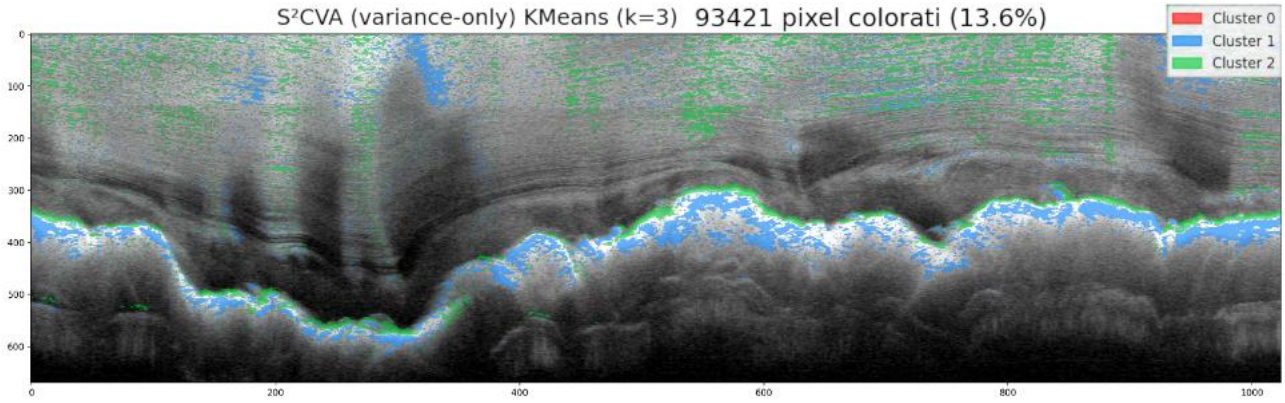
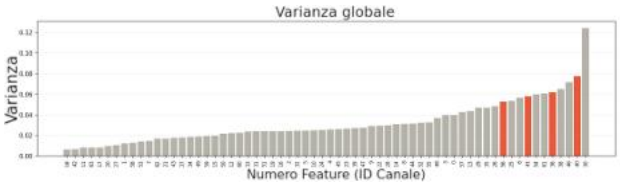


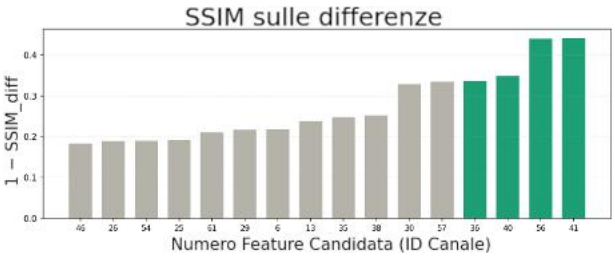
Figura 27: Feature selezionate rappresentate nell'istogramma della varianza (feature 30, 40, 46 e 38), clustering nello spazio S2CVA e overlay dei pixel cambiati.

Possiamo definire i risultati della S2CVA come simile alla classica CVA, e quindi troviamo poche differenze utili tra CVA e S2CVA.

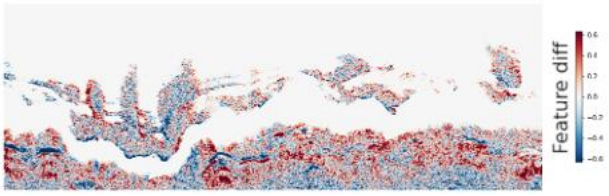
ESPERIMENTO 9: GHIACCIO BASALE (Figura 28)



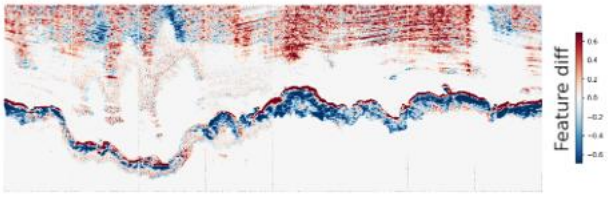
(a) Istogramma della varianza



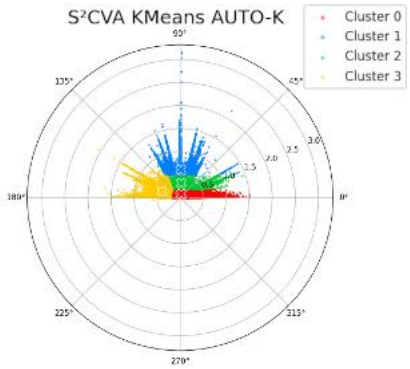
(b) Istogramma della SSIM



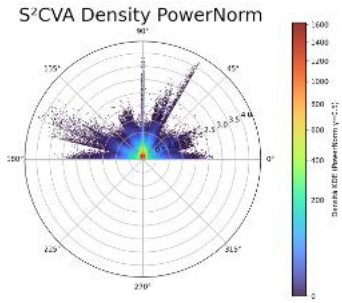
(c) Feature map 41



(d) Feature map 40



(e) Cluster



(f) Densità KDE

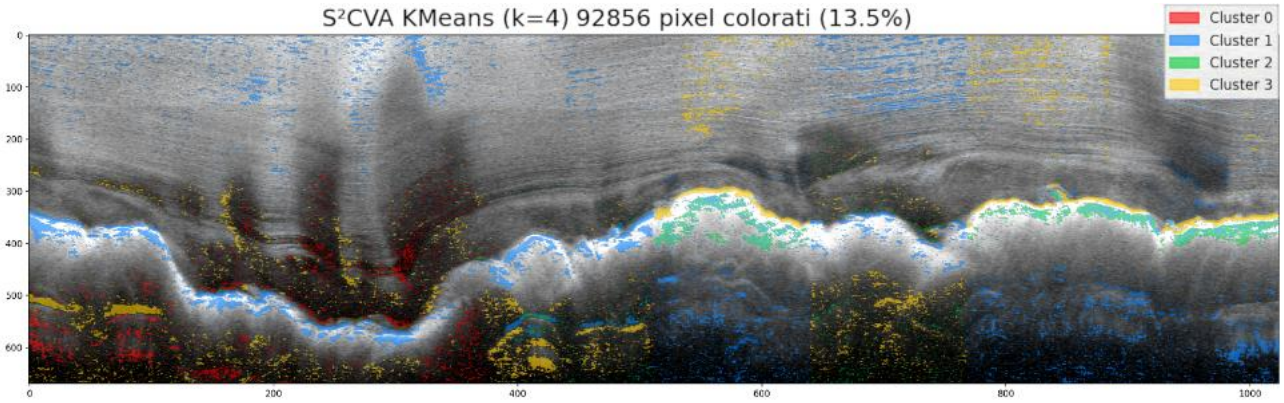


Figura 28: Istogrammi della varianza e della SSIM (feature 41, 56, 40 e 36), feature map selezionate, clustering nello spazio S2CVA e overlay dei pixel cambiati.

Come nell'esempio tra ESPERIMENTO 6 e 7 anche nelle immagini tra ESPERIMENTO 8 e 9 possiamo affermare che la SSIM migliora anche in questo caso la selezione delle feature e le rende complementari in quanto ogni feature descrive un diverso cambiamento e determina quindi una migliore identificazione.

COMMENTO RISULTATI

Per la fase di train possiamo determinare che le reti con la tv loss sono propense a creare cluster sull'immagine molto più compatti e meno sgranati, fornendo quindi una maggiore definizione (si nota questo fenomeno nella Figura 22 e Figura 24). Per quanto riguarda la rete nelle fasi iniziali quando ha una struttura poco profonda e poco complessa (3 convoluzioni) non riesce a mantenere quella continuità sul cambiamento come si osserva nelle immagini a falso colore ma tende a riconoscere pixel di cambiamento sparsi (Figura 16). La rete stessa mostra grandi miglioramenti quando si va a modificare la struttura, dove si può denotare come la ASPP influenza nel togliere molti pixel rumorosi e sparsi (Figura 18). La BiConvLSTM invece aumenta la coerenza sui cluster nell'overlay, quasi paragonabilmente alla tv loss, perchè dà maggiore corpo e pienezza alle regioni rilevate confermandosi un'aggiunta adatta alla rete. Inoltre, anche gli scatter polari definiti dalla CVA sono molto più separati in zone e non disordinati e poco densi con l'aggiunta di ASPP e BiConvLSTM (Figura 22).
Per la selezione delle feature, possiamo notare che la SSIM, in particolare, rende gli overlay senza rumore e senza pixel sparsi andando a togliere i pixel scomposti e tenendo i pixel con maggiore cambiamento e che fanno parte di una macchia di cambiamento. Dalle feature map che la SSIM va a selezionare, possiamo vedere che i valori sono maggiormente marcati, differenziati e senza dispersione di pixel ma valori concentrati (Figura 26 (d)).
Sono invece definite poche differenze tra PCA+CVA e S2CVA che cambiano solo la disposizione sullo scatterplot e la conseguente clusterizzazione.

Conclusioni

Lo studio si occupa di analizzare e utilizzare gli strumenti di analisi disponibili per rilevare i cambiamenti multitemporali sui radargrammi, basandosi sui diversi risultati ottenuti. Possiamo definire il punto di partenza del lavoro svolto come una shallow network con l'analisi della CVA e quindi solo l'analisi sullo scatterplot. Il passaggio successivo è stato aggiungere la ASPP alla struttura della rete e andare a clusterizzare manualmente gli scatter polari, per poi andare a portare tali analisi tramite overlay sull'immagine originale e ottenere così i primi risultati sui radargrammi. Successivamente è stata aggiunta la BiConvLSTM alla rete e sono state comparate le varie reti con o senza tv loss.

Il percorso svolto ha portato a un continuo miglioramento con un'analisi sempre più accurata e focalizzata verso il rilevamento dei cambiamenti sulla stratigrafia dei radargrammi.

Per gli sviluppi futuri del progetto sarebbe prevedibile una stima della massa sciolta e quantificare gli effettivi cambiamenti sfruttando questi strumenti per determinare e studiare quantitativamente ciò che accade in Antartide. Lo sviluppo di un framework o un'API in grado di rendere più user-friendly tali metodi renderebbe più semplice l'analisi ai glaciologi e potrebbe essere un'evoluzione del progetto.

Riferimenti bibliografici

[1] Francesca Bovolo e Lorenzo Bruzzone. "A Theoretical Framework for Unsupervised Change Detection Based on Change Vector Analysis in the Polar Domain". In: *IEEE Transactions on Geoscience and Remote Sensing* 45.1 (2007), pp. 218–236. DOI: 10.1109/TGRS.2006.885408.

[2] Lorenzo Bruzzone. *Radar for Imaging*. Diapositive PowerPoint - Remote Sensing and Image Analysis. 2025.

[3] Liang-Chieh Chen et al. "Rethinking Atrous Convolution for Semantic Image Segmentation". In: *CoRR* abs/1706.05587 (2017). arXiv: 1706.05587. URL: http://arxiv.org/abs/1706.05587.

[4] Jordy Dal Corso e Lorenzo Bruzzone. "A Convolutional Recurrent Bottleneck and Vertical Nonlocal Operations for the Weakly Supervised Semantic Segmentation of Radar Sounder Data". In: *IEEE Transactions on Geoscience and Remote Sensing* 63 (2025), pp. 1–20. DOI: 10.1109/TGRS.2025.3578766.

[5] Elena Donini. "Advanced methods for simulation-based performance assessment and analysis of radar sounder data". In: Università degli studi di Trento, 2021.

[6] Elena Donini, Miguel Hoyo García e Francesca Bovolo. "A preliminary study on the multitemporal analysis of cryosphere radar sounder data". In: *Artificial Intelligence and Image and Signal Processing for Remote Sensing XXX*. Vol. 13196. SPIE. 2024, pp. 208–216.

[7] Elena Donini et al. "Co-Registration Analysis of Coherent Multitemporal Radargrams". In: *IGARSS 2025 - 2025 IEEE International Geoscience and Remote Sensing Symposium*. 2025, pp. 9258–9262. DOI: 10.1109/IGARSS55030.2025.11243308.

[8] Elena Donini et al. "Unsupervised semantic segmentation of radar sounder data using contrastive learning". In: *Image and Signal Processing for Remote Sensing XXVIII*. Vol. 12267. SPIE. 2022, pp. 171–180.

[9] Aniekan Essien e Cinzia Giannetti. "A Deep Learning Model for Smart Manufacturing Using Convolutional LSTM Neural Network Autoencoders". In: *IEEE Transactions on Industrial Informatics* 16.9 (2020), pp. 6069–6078. DOI: 10.1109/TII.2020.2967556.

[10] Mehran Javanmardi et al. "Unsupervised Total Variation Loss for Semi-supervised Deep Learning of Semantic Segmentation". In: *CoRR* abs/1605.01368 (2016). arXiv: 1605.01368. URL: http://arxiv.org/abs/1605.01368.

[11] Sicong Liu et al. "Sequential Spectral Change Vector Analysis for Iteratively Discovering and Detecting Multiple Changes in Hyperspectral Images". In: *IEEE Transactions on Geoscience and Remote Sensing* 53.8 (2015), pp. 4363–4378. DOI: 10.1109/TGRS.2015.2396686.

[12] Jim Nilsson e Tomas Akenine-Möller. *Understanding SSIM*. 2020. arXiv: 2006.13846 [eess.IV]. URL: https://arxiv.org/abs/2006.13846.

[13] Changzhen Qiu et al. "Performance comparison of target classification in SAR images based on PCA and 2D-PCA features". In: *2009 2nd Asian-Pacific Conference on Synthetic Aperture Radar*. IEEE. 2009, pp. 868–871.

[14] Sudipan Saha, Francesca Bovolo e Lorenzo Bruzzone. "Unsupervised Deep Change Vector Analysis for Multiple-Change Detection in VHR Images". In: *IEEE Transactions on Geoscience and Remote Sensing* 57.6 (2019), pp. 3677–3693. DOI: 10.1109/TGRS.2018.2886643.

[15] Douglas Steinley. "K-means clustering: a half-century synthesis". In: *British Journal of Mathematical and Statistical Psychology* 59.1 (2006), pp. 1–34.

[16] Chunlai Wang, Bin Yang e Yiwen Liao. "Unsupervised image segmentation using convolutional autoencoder with total variation regularization as preprocessing". In: *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2017, pp. 1877–1881. DOI: 10.1109/ICASSP.2017.7952482.

[17] Baiq Nikum Yulisasih et al. "Evaluation of K-Means Clustering Using Silhouette Score Method on Customer Segmentation". In: *ILKOM Jurnal Ilmiah* 16.3 (2024), pp. 330–342.

Elenco delle figure

1 Esempio di un'immagine radar sounder. 2
2 Esempio di un'immagine false color su un radargramma (tra il 2014 e il 2016) dove definiamo come colore prevalente 2014 in verde e 2016 magenta. 3
3 Direzioni e definizioni degli orientamenti [5]. 6
4 Esempio di un'immagine radar sounder che dimostra l'eco dell'onda sull'acqua e sulle interfacce glaciali [5]. 8
5 Funzionamento del SAR (Synthetic Aperture Radar): Il velivolo prosegue lungo la sua direzione di volo e cattura più volte la stessa porzione di ghiaccio e ne ricostruisce un'immagine più definita [2]. 8
6 Catena dei processi effettuati per l'analisi, tratteggiati i procedimenti e linee continue i dati e risultati. 10
7 Operazione post train che permette di verificare che la rete sappia ricostruire le immagini e quindi vedere l'output della rete e paragonarlo all'immagine originale: $in - out$ (per trovare le differenze). Sulla riga superiore abbiamo le immagini del 2014 mentre in quella inferiore 2016. Determiniamo che con le immagini del 2016 dove non avviene il train la differenza ha maggiore intensità (marcato in rosso). 11
8 Architettura della Shallow-net. 16
9 Modulo LSTM [9]. 17
10 Tracce delle campagne 2014103-04 in rosso e 2016103-06 in verde. [6] 20
11 Geometria di acquisizione di due tracce e delle loro impronte. Da sinistra, le impronte sono completamente sovrapposte, non sovrapposte e parzialmente sovrapposte. [7] 21
12 Correlazione incrociata dei radargrammi Rt1 in verde e Rt2 in rosso: i riquadri bianchi indicano i quattro sotto-radargrammi che vengono correlati separatamente, e le frecce blu indicano le direzioni della correlazione incrociata [6]. 21
13 (a) Radargramma nel 2014, (b) radargramma nel 2016 e (c) rappresentazione in falso colore della stessa area, utilizzata per evidenziare i cambiamenti. 24
14 (a) Radargramma nel 2014, (b) radargramma nel 2016 e (c) rappresentazione falso colore in modo da notare i cambiamenti. Patch estratta da un radargramma del dataset in una zona inferiore rappresentante cambio di stratigrafia. 24
15 Risultati SHALLOW-CNN per ghiaccio centrale: (a) clustering nello spazio CVA, (b) densità KDE e overlay dei pixel cambiati sul radargramma 2014. 26
16 Risultati SHALLOW-CNN per ghiaccio basale: (a) clustering nello spazio CVA, (b) densità KDE e (c) overlay dei pixel cambiati sul radargramma 2014. 26
17 Risultati ASPP + SHALLOW-CNN (Train MSE + TVLOSS) per ghiaccio centrale: (a) clustering nello spazio CVA, (b) densità KDE e (c) overlay dei pixel cambiati sul radargramma 2014. . . 27
18 Risultati ASPP + SHALLOW-CNN (Train MSE + TVLOSS) per ghiaccio basale: (a) clustering nello spazio CVA, (b) densità KDE e (c) overlay dei pixel cambiati sul radargramma 2014. . . 27
19 Risultati ASPP + SHALLOW-CNN (Train solo MSE) per ghiaccio centrale: (a) clustering nello spazio CVA e (b) overlay dei pixel cambiati sul radargramma 2014. 28
20 Risultati ASPP + SHALLOW-CNN (Train solo MSE) per ghiaccio basale: (a) clustering nello spazio CVA, (b) densità KDE e (c) overlay dei pixel cambiati sul radargramma 2014. 28
21 Risultati LSTM + ASPP + SHALLOW-CNN (Train MSE + TVLOSS) per ghiaccio centrale: (a) clustering nello spazio CVA e (b) overlay dei pixel cambiati sul radargramma 2014. 29
22 Risultati LSTM + ASPP + SHALLOW-CNN (Train MSE + TVLOSS) per ghiaccio basale: (a) clustering nello spazio CVA, (b) densità KDE e (c) overlay dei pixel cambiati sul radargramma 2014. 29
23 Risultati LSTM + ASPP + SHALLOW-CNN (Train solo MSE) per ghiaccio centrale: (a) clustering nello spazio CVA e (b) overlay dei pixel cambiati sul radargramma 2014. 30
24 Risultati LSTM + ASPP + SHALLOW-CNN (Train solo MSE) per ghiaccio basale: (a) clustering nello spazio CVA, (b) densità KDE e (c) overlay dei pixel cambiati sul radargramma 2014. . . 30

25 Istogramma della varianza, feature selezionate rappresentate nell'istogramma della varianza (feature 30, 40, 46 e 38), clustering nello spazio PCA-CVA e overlay dei pixel cambiati. 32
26 Istogrammi della varianza e della SSIM (feature 41, 56, 40 e 36), feature map selezionate, clustering nello spazio CVA-SSIM e overlay dei pixel cambiati. 33
27 Feature selezionate rappresentate nell'istogramma della varianza (feature 30, 40, 46 e 38), clustering nello spazio S2CVA e overlay dei pixel cambiati. 34
28 Istogrammi della varianza e della SSIM (feature 41, 56, 40 e 36), feature map selezionate, clustering nello spazio S2CVA e overlay dei pixel cambiati. 35